شباهنگ

نشریه‌ی دانشکده‌ی فیزیک دانشگاه صنعتی شریف
شماره‌ی هفدهم اسفند ماه ۱۴۰۰

علم داده و یادگیری ماشین در کیهان‌شناسی



مصاحبه با دکتر موحد و دکتر وفایی‌صدر



Kyle Goetsch
NIKON CORPORATION, NIKON D600
http://unsplash.com/photos/VxaZjhobxFw

شباهنگ

با حمایت و پشتیبانی دبیرخانه نشریات دانشگاه صنعتی شریف

صاحب امتیاز: **انجمن علمی دانشکده فیزیک دانشگاه صنعتی شریف**
مدیر مسئول: **دکتر شانت باغرام**
سردبیر: **درسا نجفی‌پناه**
صفحه‌آرا: **فرشته دشتکی**
طراح جلد: **مهدی سلیمان‌زاده**
ویراستاران نگارشی: **فرشید غلامی، حانیه ملکی، آوین محبی، علی اکرامیان**
مصاحبه‌گر: **امیرحسین فیض**
نویسندگان این شماره: **نگین خسروانی‌نژاد**/ کارشناسی فیزیک شریف، **هاله مسگری**/ دستیار پژوهشی پژوهشگاه دانش های بنیادی، **فریدا فارسیان**/ محقق پسادکتری فیزیک دانشگاه بولونیا ایتالیا، **آوین محبی**/ دانشجوی کارشناسی فیزیک شریف

با سپاس از: **دکتر سید محمدصادق موحد**/ عضو هیئت علمی دانشکده فیزیک دانشگاه شهید بهشتی، **دکتر علیرضا وفایی‌صدر**/ محقق پسادکتری دانشگاه ژنو سوئیس

سرمقاله

با تمام فرازونشیب‌های اجتماعی، سیاسی، اقتصادی و بهداشتی عصر ما، به نظر می‌رسد که بشر در آستانه‌ی انقلاب فکری دیگری است. انقلابی که آن را با نام‌هایی چون «انقلاب اطلاعاتی» یا «عصر اطلاعاتی» می‌خوانیم و می‌شنویم. همچنین مفاهیمی چون علم داده، یادگیری ماشین و هوش مصنوعی (هومص)، بیش از پیش وارد عرصه‌ی علم و اندیشه شده‌اند. جالب آنکه در حوزه‌ی نجوم و کیهان‌شناسی نیز روندی پیش گرفته شده‌است، شاید طبیعی، که مفاهیم کلان‌داده، یادگیری ماشین و هومص نیز با سرعت چشمگیری وارد عرصه شده‌اند. اگر مقالات این حوزه را روزانه از arXiv پیگیری می‌کنید، حتماً دیده‌اید که هر روز اگر نه، حتماً هر هفته، مقاله و مقالاتی از نوع استفاده‌ی کلان‌داده‌ها و یادگیری ماشین برای حل مسائل روز کیهان‌شناسی به طبع می‌رسد و برخط می‌شود.

داده‌های بسیاری که از مجموع رصدهای زمینی و آسمانی در طول موج‌های گسترده‌ی الکترومغناطیسی دریافت می‌شوند از یک سو، دریچه‌ی جدید امواج گرانشی از سوی دیگر و سوی سوم وجود شبیه‌سازی‌های اخترفیزیکی و کیهانی، خواسته و ناخواسته ما را در این عصر قرار داده‌اند. دانشجویان ما در شباهنگ شماره‌ای را آماده کرده‌اند که به‌صورت خاص به این موضوع می‌پردازد. مقالات و مصاحبه‌های این شماره به‌روز و در خطِ مقدم کیهان‌شناسی و نجوم و ارتباط آن با علم داده و یادگیری ماشین است.

خوشبختانه جامعه‌ی علمی ما آگاه به این تحول است. آن چه بی‌شک خواستنی است، حمایت و رشد این حوزه‌ی خاص از علم است. اگرچه هنوز باور دارم که این ذهن روشن انسان‌های علاقه‌مند به علم است که شگفتی‌های جدیدی را خواهد یافت ولی در عین حال باور دارم ابزاری که ساخته‌ایم، از تلسکوپ‌ها و تداخل‌سنج‌ها گرفته تا ماشین‌هایی که یاد می‌گیرند مسئله حل کنند، به ما کمک خواهند کرد که بیشتر و بهتر بدانیم.

و سرانجام کلام، باور دارم که دانشجویان کنونی ما که محققان آینده‌ی نزدیک ما خواهند بود، حتماً در این حوزه کارهای مهمی را انجام خواهند داد.

شانت باغرام

اسفند ۱۴۰۰

فهرست



Nathan Anderson
NIKON CORPORATION, NIKON D750
http://unsplash.com/photos/9o-VrJSwGuw

۶
مصاحبه با دکتر محمدصادق موحد
کاربرد علم داده و یادگیری ماشین در کیهان‌شناسی

۱۴
مصاحبه با دکتر علیرضا وفایی‌صدر
کاربرد علم داده و یادگیری ماشین در کیهان‌شناسی

۲۲
کیهان‌شناسی در سایه‌ی رصدها و داده‌های جدید
هاله مسگری

۲۴
یادگیری ماشینی به عنوان ابزاری برای شناخت و شهود پیدا کردن نسبت به مدل‌های نظری کیهان شناسی
فریدا فارسیان

۲۸
یادگیری ماشینی به عنوان ابزاری برای کار با داده‌های بزرگ
نگین خسروانی‌نژاد

۳۰
یادگیری ماشینی به عنوان جایگزینی سریع‌تر و بهینه‌تر در شبیه‌سازی‌ها
نگین خسروانی‌نژاد

مصاحبه با دکتر محمدصادق موحد

عضو هیئت علمی دانشکده فیزیک دانشگاه شهید بهشتی

۱. چه دسته‌بندی‌ها و شاخه‌هایی برای بررسی کیهان ما وجود دارد؟

علم کیهان‌شناسی هم در بازه‌های زمانی، از حدود زمان پلانک تا زمان حال، و هم در بازه‌های مکانی، از مقیاس‌های ریز تا طولی که نور در سن گذشته از کیهان طی کرده، و هم در بررسی ساختارها، از ذرات بنیادی گرفته تا ساختارهای بزرگ‌مقیاس کیهانی، بسیار گسترده است. به همین دلیل شاخه‌های متعدد پژوهشی‌ای به این علم مرتبط می‌شوند. از جهتی اگر به سوال‌های معمولی که در کیهان‌شناسی برای بشریت وجود دارند توجه کنیم، می‌توانیم به‌صورت کلی اهم شاخه‌ها را به‌صورت زیر بیان کنیم:

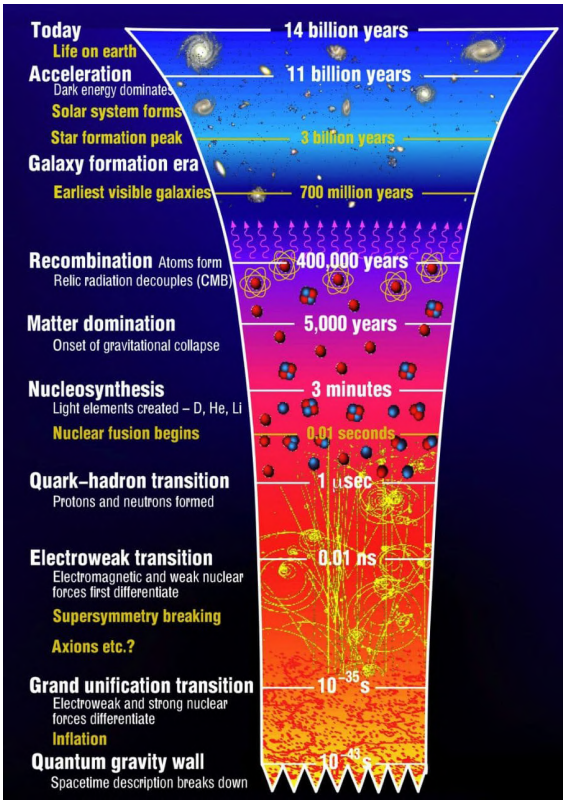
-شناخت کیهان اولیه

-شناخت تابش زمینه‌ی کیهانی؛ که شامل فوتون‌هایی می‌شود که از زمانی که سن عالم چیزی در حدود ۳۰۰ هزار سال بوده به ما می‌رسند.

-شناخت ساختارهای بزرگ‌مقیاس کیهان

-امواج گرانشی

-ماده‌ی تاریک و انرژی تاریک



مقایسه‌ی زمان‌های کیهانی و رویدادهای مربوط به هر یک[1]

1-http://www.ctc.cam.ac.uk/outreach/origins/big_bang_three.php



دکتر محمدصادق موحد

۲. بر اساس این شاخه‌ها، چه داده‌هایی و از چه منابعی در حال جمع‌آوری می‌باشند؟

قبل از پاسخ‌دادن به شما باید اشاره کنم که ما در فیزیک به‌طور کلی از امواج الکترومغناطیس و اثرات ثانویه‌ی فرآیندهای فیزیکی به‌عنوان کاوشگر استفاده می‌کنیم. اما با توجه به اینکه آخرین سطح قابل مشاهده در دریچه‌ی امواج الکترومغناطیس همان تابش زمینه‌ی کیهانی است، لذا امید برای رصد مستقیم رویدادهای ورای آن بسیار کم یا ناممکن است. اما بعد از آشکارسازی گسترده‌ی امواج گرانشی این امید که بتوان با ارتقای فناوری‌ها از دریچه‌ی اعوجاجات فضا و زمان، به‌عنوان کاوشگر استفاده کرد، جان تازه‌ای گرفته‌است. از طرفی پیشرفت‌هایی که در زمینه‌ی شبیه‌سازی‌ها صورت گرفته‌است باعث شده تا داده‌های به‌دست آمده از این شبیه‌سازی‌های بزرگ‌مقیاس نیز به‌عنوان داده‌هایی تصنعی موردتوجه پژوهشگران قرار گیرند. می‌توان گفت که داده‌های تابش زمینه‌ی کیهانی در نسل‌های آینده‌ی رصدی، با استفاده از قدرت‌های تفکیک بالا، امکان مطالعه‌ی مواردی که تا پیش از این تقریباً ناشدنی بود را فراهم می‌کنند. پروژه‌هایی نظیر SDSS و eBOSS ، داده‌های مربوط به امواج گرانشی تصادفی زمینه و همچنین امواج گرانشی ناشی از رویدادهای اخترفیزیکی کیهان اخیر مانند ادغام سیاهچاله‌ها، داده‌های مربوط به رویدادهای همگرایی گرانشی در سه گروه ریزهمگرایی، همگرایی ضعیف گرانشی (آماری) و همگرایی قوی گرانشی، داده‌های مربوط به رصد شمع‌های استاندارد یا ابرنواخترها، انفجارهای GRB، طیف‌های جذبی و نشری،

تابش ۲۱ سانتی‌متری، پروژه‌ی کیلومتر مربع، آزمایش‌های رصدی مستقیم و غیرمستقیم ماده‌ی تاریک، پروژه‌هایی نظیر DES[2] ، ZTF[3] ، از جمله مهم‌ترین منابع فعلی در حوزه‌ی کیهان‌شناسی به شمار می‌آیند. اشاره به این نکته نیز ضروری است که برخی از داده‌های رصدی توانایی به‌نمایش‌گذاشتن ویژگی‌های زمینه‌ی کیهان را دارند و برخی نیز ناظر به اختلالات هستند. به‌طور کلی مهم‌ترین کمیت‌های مشاهده‌پذیری که تحول زمینه‌ی کیهان را نشان می دهند عبارت‌اند از:

چگالی نسبی ماده‌ی تاریک	Ω_m
چگالی نسبی نوترینو	Ω_ν
چگالی نسبی ماده‌ی باریونی	Ω_b
چگالی نسبی انرژی تاریک	Ω_Λ
چگالی نسبی تابش	Ω_R
کمیت حالت (رابطه بین فشار چگالی انرژی)	w
سن کنونی کیهان	t_0
پارامتر هابل در زمان حال	H_0
پارامتر شتاب منفی در زمان حال	q_0
دمای تابش زمین کیهانی در زمان حال	T_{CMB}

جدول شماره ۱

و آن‌هایی که توصیف‌گر انحراف از اصول کیهان‌شناختی همگنی و همسانگردی هستند، عبارت‌اند از:

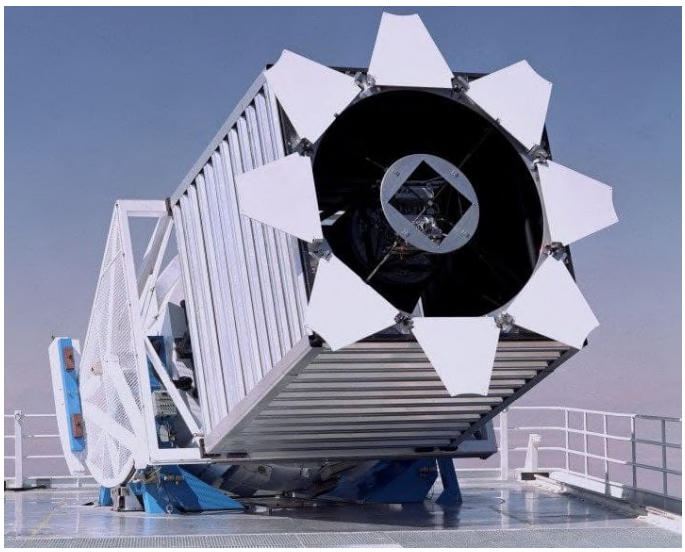
افت‌وخیز چگالی	σ_8
دامنه افت‌وخیزهای تانسوری	A_t
دامنه افت‌وخیزهای اولیه اسکالری	A_s
نمای مقیاسی افت‌وخیزهای اولیه تانسوری	n_t
نمای مقیاسی افت‌وخیزهای اولیه اسکالری	n_s
وابستگی نمای مقیاسی افت‌وخیزهای اولیه به مقیاس	$\frac{d\ln n}{d\ln k}$

جدول شماره ۲

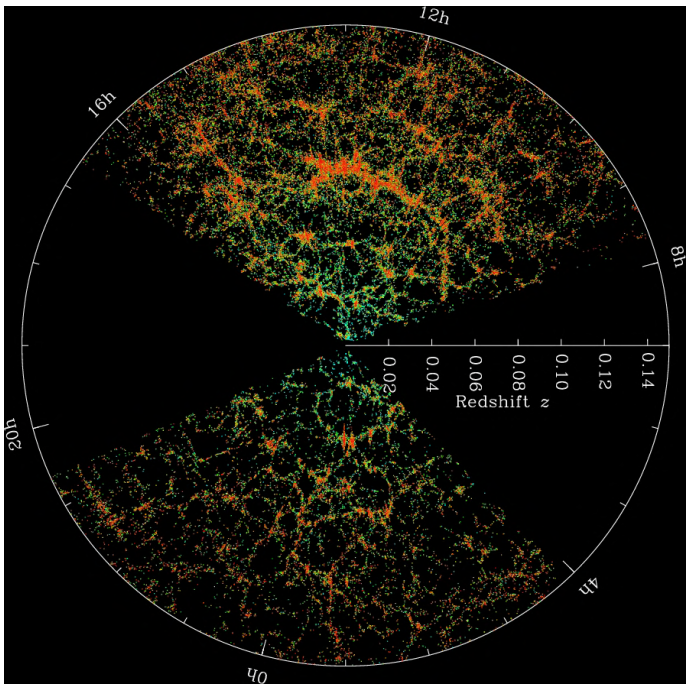
2-Dark Energy Survey (https://www.darkenergysurvey.org/)

3-Zwicky Transient Facility (https://www.ztf.caltech.edu/)

لذا پروژه‌های رصدی اغلب به‌نحوی طراحی می‌شوند که بتوانند به‌صورت مستقیم یا غیرمستقیم اطلاعاتی را در خصوص کمیت‌های مذکور فراهم کنند.



SDSS Telescope[4]



SDSS Galaxy map[5]

4-https://www.nanowerk.com/news2/space/newsid=55735.php

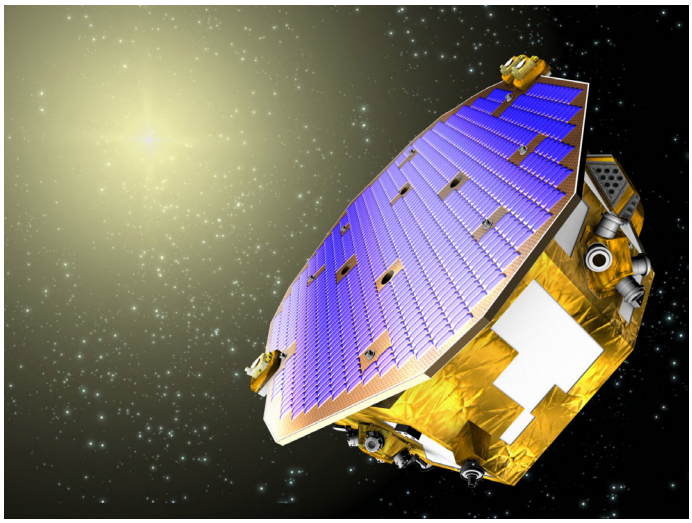
5-https://uwaterloo.ca/physics-astronomy/events/perseids-sky-watching-party-and-lecture-mapping-universe

۳. می‌توانید چند نمونه از تلسکوپ‌های زمینی یا فضایی مهمی که در سال‌های اخیر شروع به کار کرده یا در سال‌های آینده شروع به کار خواهند کرد نام ببرید؟

پروژه‌هایی مانند CMB-S4 که نسل آینده‌ی رصدگر تابش زمینه‌ی کیهانی است، SKA که بزرگترین تلاش بین‌المللی برای ساخت تلسکوپ‌های رادیویی است، پروژه‌ی Advanced Ligo و پروژه‌ی LISA که برای رصد امواج گرانشی هستند، پروژه‌های مبتنی بر رصد تپ‌اخترها برای رصد امواج گرانشی، پروژه‌ی جیمز وب (JWST) جهت رصد امواج در طیف فروسرخ و تلسکوپ بزرگ نقشه‌برداری سینوپتیک (LSST) جهت بررسی ابرنواخترها، بررسی دقیق‌تر ماهیت انرژی تاریک و ...



CMB-S4[6]



LISA[7]

۴. از دلایل پذیرفتن یا نپذیرفتن مدل استاندارد کیهان شناسی و مسیری که جامعه‌ی علمی امروزه پیش گرفته‌است بگویید.

برای دستیابی به یک معرفت علمی از چهارچوبی که در آن، ابزار ریاضی برای مدل‌سازی جهت توصیف رفتار طبیعت است، استفاده می‌شود. مدلی در این رهیافت بهتر (نه لزوماً واقعی‌تر) است که به‌طور کلی ساده‌تر و با اندازه‌گیری‌ها، مشاهدات و رصدها سازگارتر باشد. بنابراین مادامی که پیش‌بینی‌های قابل مشاهده و معیارهایی که بتوان تمایزی برای آنها قائل شد ارائه نشوند، کماکان همه‌ی مدل‌ها قابل‌قبول بوده و هیچ ارجحیتی نسبت به هم ندارند. برای پاسخ به سوالاتی در خصوص طبیعت و ماهیت آن، تحول و احتمالا پیش‌بینی وضعیت آینده‌ی آن، مدلی بنا می‌شود. در این مدل باید مشاهده‌پذیرها و اندازه‌پذیرها تعیین شوند. از سویی دیگر باید با کمک ابزارهای مناسب به رصد و مشاهده پرداخت و مقادیر مشاهده‌پذیرها را تعیین کرد. در چهارچوب مدل‌کردن داده‌ها یعنی مقایسه نظریه و مشاهده، سازگاری مدل با رصد سنجیده می‌شود. برای بررسی تمام جوانب و ایده‌های جدید نیازمند انجام شبیه‌سازی نیز هستیم که البته این کار خود بازخوردهایی را برای مشاهدات، اندازه‌گیرها و رصدهای آینده و همچنین نظریه‌پردازی به دنبال خواهد داشت. علی‌الاصول یک نظریه موفق کیهان‌شناختی باید تا آنجا که می‌تواند به سؤالاتی از قبیل؛ مبداء کیهان ما چیست و کجاست؟ کیهان ما از چه اجزایی تشکیل شده و از چه ساخته شده‌است؟ اندازه و سن کیهان ما چقدر است؟ شکل کیهان ما چگونه است؟ منشاء ساختارهایی نظیر منظومه‌ها، کهکشان‌ها و خوشه‌هایی که امروزه مشاهده می‌کنیم چیست؟ آینده‌ی عالم ما چگونه است؟ و سایر سؤالاتی از این دست، پاسخی سازگار و عقلانی ارائه دهد. با این مقدمه، مدل استاندارد کیهان‌شناسی با حداقل پارامترهای آزاد در مقایسه با سایر نظریه‌ها، توانسته پیش‌بینی‌ها و همچنین سازگاری‌هایی بسیار چشمگیر، از رصدهای کیهان اخیر و کیهان اولیه ارائه دهد. البته با ارتقای دقت اندازه‌گیری، اکنون مواردی از ناهمخوانی به‌عنوان ناهنجاری پدید آمده‌است. این شرایط البته در دوره‌های دیگری نیز در حوزه‌ی کیهان‌شناسی و همچنین سایر حوزه‌های علمی نیز پدید آمده و منجر به باز شدن دریچه‌ای جدید برای فهم ما از جهان طبیعت شده‌است.

6-https://wowtravel.me/the-12-best-astronomical-observatories-around-the-world/

7-https://www.gov.uk/government/case-studies/lisa-pathfinder

۵. با توجه به اشاره‌ای که در ابتدا به کلان‌داده‌ها داشتیم، چه مجموعه‌ی داده‌ای را کلان‌داده (Big Data) می نامیم. آیا امکان تغییر این مفهوم با گذشت زمان وجود دارد؟

به نظر می‌رسد که از جمله اولین مراکزی که عبارت big data را به کار برده‌است NASA در سال ۱۹۹۷ است. کلان‌داده دارای سه ویژگی مهم است؛ یعنی کلان‌بودن از حیث اندازه (Volume)، کلان‌بودن از حیث داشتن آهنگ تولید بسیار چشمگیر(Velocity or Production rate) و کلان‌بودن از حیث تنوع زیاد (Variaty). گاهی نیز کلان‌داده را VVV در نظر می‌گیرند. البته درحوزه‌ی کیهان‌شناسی ممکن است یک یا دو ویژگی مذکور به‌طور هم‌زمان برای یک دسته از داده‌ها که ادعا می‌کنیم جزء کلان‌داده محسوب می‌شوند، وجود نداشته‌باشند. از منظر فیزیک نیز می‌توان اضافه کرد که این مفهوم را یک بار دیگر در جایی مانند ترمودینامیک تجربه کرده‌ایم. آنجایی که رفتارهای مقیاس ماکروسکوپیک الزاماً در حد ترمودینامیک اهمیت پیدا می‌کند. در خصوص وابستگی مفهوم کلان‌داده به زمان، نظر من بر این است که از آنجا که کلان‌داده خود محصول است و نه معلول، لذا هرگونه تغییری می‌تواند داشته‌باشد. از این منظر، باید گفت تصور از کلان‌داده در علم کیهان‌شناسی با آن چیزی که در حدود ۳۰ تا ۴۰ سال پیش وجود داشت با تغییرات بنیادینی مواجه شده‌است. این تغییرات بنیادین نه صرفاً به‌دلیل حجم داده بلکه به‌خاطر تغییر نگرش مواجه با آن‌ها برای استخراج علم نیز است. اکنون پارادایم علم داده‌محور نیز بیش از پیش در کیهان‌شناسی رسوخ پیدا کرده است. این درحالی است که در حدود ۱۰ سال پیش گفت‌وگو از این رویکرد با برچسب گفتمان غیرعلمی مواجه بود. لذا به نظر من مفهوم آن با گذشت زمان برای فیزیک‌دانان از این جهت عوض شده که نگریستن به داده‌ها فقط به مثابه ابزاری به‌منظور مقیدکردن کمیت‌های مدل‌های نظری نیست و جست‌وجوگری برای به‌کاربستن روش‌های محاسباتی مناسب برای استخراج معرفت علمی نیز شروع شده‌است. البته اگر به کلان‌داده، صرفاً از منظر ماهیت کلان‌داده توجه شود در آن صورت قول دیگری نیز می‌تواند درست باشد و آن اینکه ویژگی کلان‌داده به‌مثابه‌ی خواص ماکروسکوپیک سیستم است و تا زمانی که حواس ما تغییر نکند، مفاهیمی که توسط کمیت‌های ماکروسکوپیک حمل می‌شود تغییر نمی‌کند. اما در صورتی که حواس ما تغییر کند، مفهوم کمیت ماکروسکوپیک و در نتیجه مفهوم کلان‌داده می‌تواند تغییر کند.

۶. چالش های کار با داده‌های بزرگ چیست؟

چالش‌ها را می‌توان به دو بخش سخت‌افزاری و نرم‌افزاری تقسیم‌بندی کرد. در بخش سخت‌افزاری همان طور که از اسمش پیداست عمده‌ی چالش در انتقال داده‌ها و همچنین محدودیت‌هایی نظیر سروکله‌زدن با داده توسط سخت‌افزارهای قابل دسترس است و در نتیجه نیاز به صرف زمان زیاد است. اما دربخش نرم‌افزاری موضوع کمی پیچیده‌تر است. ابزارهای داده‌کاهی، از تمیزکردن داده‌ها تا روش‌های تحلیل و بررسی و الگوریتم‌ها، لازم است تغییرات بنیادینی داشته‌باشد. روش‌های مرسوم تحلیل داده‌ها باعث می‌شود که از ظرفیت‌ها و پتانسیل‌های نهفته در آن‌ها به‌طور کامل استفاده نشود.

۷. راه حل‌های این چالش‌ها چیست؟

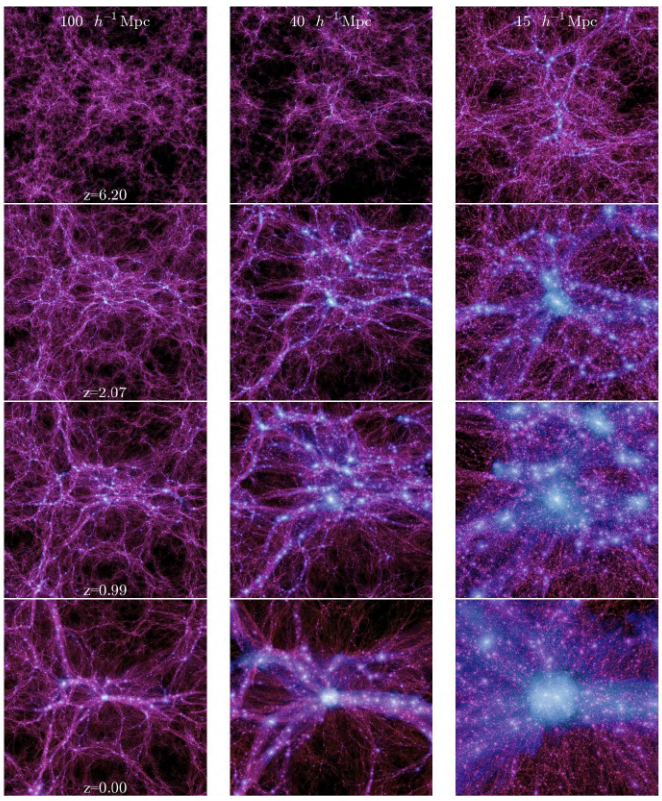
در بخش سخت‌افزاری جواب واضح است، اما به‌نظر من در بخش نرم‌افزاری لازم است به ابزارها و الگوریتم‌های جدید تحلیل آن‌ها مجهز شد.

۸. حال که صحبت از کلان‌داده‌ها شد، می‌توانید به چند مورد از آن‌ها در علم نجوم و کیهان‌شناسی نیز اشاره کنید؟

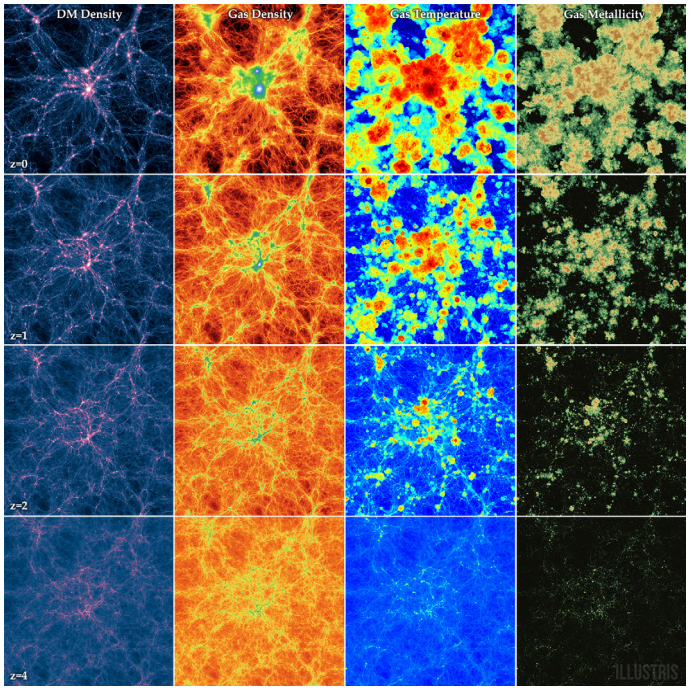
داده‌های تابش زمینه‌ی کیهانی که در نتایج منتشرشده توسط ماهواره‌ی پلانک وجود دارند؛ با داده‌هایی بالغ بر ۵۰ میلیون داده در ۹ باند فرکانسی در بخش افت‌وخیز دمایی و بخش دیگری نیز که به قطبش این تابش مرتبط است. در خصوص مساحی‌های ساختارها نیز می‌توان به مساحی آسمان دیجیتال اسلون (SDSS) اشاره کرد که در هر برون‌داد از نتایج خود، حجم داده‌ای از مرتبه‌ی صد ترابایت ارائه می‌کند. برای مثال در شبیه‌سازی‌های ساختارهای بزرگ کیهانی نظیر Illustris، Millennium، حجم داده‌های خام از مرتبه‌ی ۲۵۰ ترابایت است. (در شبیه‌سازی‌ها معمولاً حجم داده مطرح نیست، چرا که شبیه‌سازی در سرورهای از قبل تعریف شده مورد استفاده قرار می‌گیرد).

در پروژه‌ی یک میلیارد دلاری کیلومترمربع (SKA) پیش‌بینی می شود که بالغ بر ۴۰۰ گیگابایت داده در هر ثانیه تولید شود این در حالی است که در پروژه شتاب‌دهنده‌ی سرن به طور متوسط تولید ۲۵ گیگابایت داده در هر ثانیه انجام شده‌است.

در جدول شماره‌ی ۳ نیز حجم داده‌های چند پروژه معروف را می توانید مشاهده کنید:



شبیه سازی Millennium[۸]



شبیه سازی Illustris[۹]

Sky Survey Projects	Data Volume
DPOSS (The Palomar Digital Sky Survey)	3 TB
2MASS(The Two Micron All-Sky Survey)	10 TB
GBT(Green Bank Telescope)	20 PB
GALEX(The Galaxy Evolution Explorer)	30 TB
SDSS(The Sloan Digital Sky Survey)	40 TB
SkyMapper Southern Sky Survey	500 TB
PanSTARRS(The Panoramic Survey Telescope and Rapid Response System)	~ 40 PB expected
LSST(The Large Synoptic Survey Telescope)	~ 200 PB expected
SKA(The Square Kilometer Array)	~ 4.6 EB expected

جدول شماره ۳

منبع جدول شماره ۳:

Cui, Chenzhou, et al. «Astronomy research in big-data era.» Chinese Science Bulletin 60.5-6 (2015): 445-449.

8-https://www.researchgate.net/figure/Example-of-structure-formation-as-a-function-of-time-in-the-Millennium-II-simulation_fig5_51937902

9-https://www.forbes.com/sites/kevinanderton/2020/10/31/heat-is-building-up-in-galaxies-across-the-universe-infographic/amp/

۹. آیا می‌توان دسته‌بندی خاصی برای تحلیل داده بیان کرد؟

از نقطه‌نظر اهداف می‌توان گفت تحلیل داده‌ها به دسته‌ی تحلیل پسینی (Posterior analysis)، استفاده از داده در شبیه‌سازی‌ها و همچنین کاربست داده‌ها در علم داده‌محور، تقسیم بندی می‌شود.

۱۰. خارج از داده‌های مشاهده (Observe) به چه دلیل سراغ شبیه‌سازی می‌رویم؟

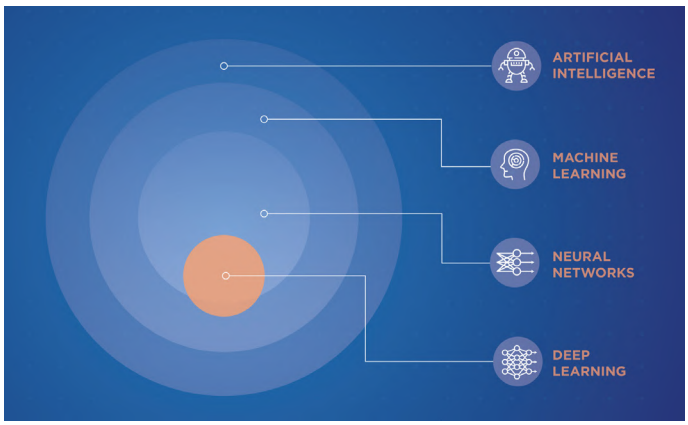
همان‌طور که در سؤالات قبل اشاره کردم، زمان‌بر و هزینه‌بر بودن انجام آزمایش‌ها از یک سو و همچنین دغدغه برای تعیین خط مشی بهینه برای انجام آزمایش‌ها و احتراز هر چه بیشتر از اتخاذ رویکرد آزمون و خطا از جمله دلایل توجه به انجام شبیه‌سازی‌ها به شمار می‌رود. همچنین انجام شبیه‌سازی می‌تواند بازخوردی برای مدل‌سازی و نظریه‌پردازی نیز در پی داشته‌باشد.

۱۱. حال آیا ممکن است که شبیه‌سازی‌ها ما را گمراه کنند؟

دقت کنید که چه موقع می‌توان گفت که قادر خواهیم بود شبیه‌سازی انجام دهیم؟ به‌واقع در شبیه‌سازی اغلب طبیعت و محیط اطراف ما منشاء تولید مسئله‌ها هستند. نظریه‌ها در بستر مدل‌ها تدوین می‌شوند. روش‌ها توسط الگوریتم‌ها پیاده‌سازی می‌شوند و نهایتاً برنامه‌های رایانه‌ای بخش آخر تولید یک شبیه‌سازی را تشکیل می‌دهد. با عنایت به این توصیف، به روشنی درمی‌یابیم که در شبیه‌سازی‌ها امکان تولید تصنعی فرآیندهایی که در طبیعت رخ می‌دهند وجود دارد. اما آیا هر نتیجه‌ای که در شبیه‌سازی به‌دست می‌آید، قابل اعتماد است؟ پاسخ این سوال به این نکته ظریف برمی‌گردد که رایانه هرچیزی که ما به آن داده‌ایم اجرا می‌کند و نه آن چیزی را که انتظار داریم. لذا حداقل دو منشاء وجود دارد که باعث می‌شود نتایج به‌دست آمده با قطعیت مورد استناد نباشد. اول اینکه مدل‌های نظری که استخراج شده‌اند ممکن است تمام آنچه را که در طبیعت رخ می‌دهد را پوشش ندهد. در نتیجه، پیش‌بینی‌های حاصل از شبیه‌سازی ممکن است دچار خدشه باشد. دوم اینکه الگوریتم‌های به‌کار گرفته‌شده اساساً خود دارای محدودیت‌های ذاتی هستند و این محدودیت‌ها ممکن است در برخی اوقات با اهمیت باشند.

۱۲. رابطه‌ی علم داده، هوش مصنوعی، یادگیری ماشین و شبکه‌های عصبی به چه شکل است؟

هوش مصنوعی مفهومی نظری با هدف توسعه‌ی ماشین برای انجام وظایفی است که به‌طور معمول برای اجرای آن‌ها نیاز به هوش انسانی است. با این تعریف، هوش مصنوعی مفهومی کلی است که در خیلی از حوزه‌ها کاربرد داشته و نیازمندی‌های فراوانی از قبیل شبکه، استخراج داده، داده‌های حجیم و غیره برای توسعه‌ی آن وجود دارد. یادگیری ماشین بخش مهمی از فرآیند توسعه در هوش مصنوعی است. شبکه‌های عصبی یکی از روش‌های مرسوم در یادگیری ماشین است. روش‌های دیگری مانند روش بردار پشتیبان، درخت تصیمم و غیره نیز در یادگیری ماشین کاربرد دارند و در برخی موارد حتی استفاده از آن‌ها بهینه‌تر از استفاده از شبکه‌ی عصبی است. از طرفی در علم داده در واقع تأکید ما بر استخراج دانش از داده است. این موضوع به‌صورت ویژه وقتی که با داده‌های بزرگ یا داده‌های با خطای زیاد، داده‌های غیرساختارمند و مانند آن مواجه هستیم، اهمیت پیدا می‌کند. یکی از ابزارهایی که برای جست‌وجو در داده‌ها و استخراج علم و دانش به‌کار گرفته می‌شود، الگوریتم‌های توسعه‌یافته در حوزه‌ی یادگیری ماشین است. در این حالت ماشین وظیفه دارد تا بر اساس در خواست ما، روابط معنی‌دار را از داده‌های پیچیده استخراج کند. ما درخواست خود را بر روی الگوریتم‌های یادگیری ماشین اعمال می‌کنیم. برای مثال دسته‌بندی داده‌ها طبق ویژگی‌هایی که برای ما اهمیت دارد می‌تواند یک درخواست باشد. یا تخمین نتیجه در صورتی که ویژگی‌های مشخصی در داده به وقوع بپیوندند. در نهایت می‌توان گفت که شبکه‌های عصبی زیرمجموعه‌ی یادگیری ماشین و یادگیری ماشین نیز زیرمجموعه‌ی هوش مصنوعی می‌باشد.



the scientist staff [10]

10-https://www.the-scientist.com/magazine-issue/artificial-intelligence-versus-neural-networks-65802

۱۳. هنگام بررسی داده‌ها، مثلاً برای مسائلی مانند طبقه‌بندی، ابزارهای آماری و ابزارهای یادگیری ماشین و یادگیری عمیق را در دسترس داریم. چالش های استفاده از هر کدام از این موارد چیست؟

اول از همه باید تا آنجا که امکان دارد نسبت به داده‌ها شهود کافی یافت. بر اساس تجربه‌ی شخصی خودم، ابتدا سعی می‌کنم که تا آنجا که امکان دارد داده‌ها را به تصویر تبدیل کنم تا با آن‌ها ارتباط عینی ایجاد شود. در مرحله‌ی بعد باید به این سوال پاسخ داد که آیا صرفاً طبقه‌بندی برای کار ما کفایت می‌کند؟ و مسئله را باید با نگاه صرفا نتیجه‌محوری نگریست؟ اگر پاسخ این گونه سوالات مثبت است، روشی باید اتخاذ شود که هم با دقت و هم با سرعت بالا بتواند به‌نحو قابل‌اعتمادی طبقه‌بندی را انجام دهد. اگر دسته‌ی داده‌های مورد بررسی را بتوان به‌عنوان یک کلان‌داده شناخت، استفاده از روش‌های یادگیری ماشین به مراتب می‌تواند اثربخش باشد. در یادگیری عمیق نیز الزاماً به دسته‌ی داده‌های بسیار بزرگ برای فرآیند یادگیری نیاز است. هرچند که در تحقیقاتی نشان داده شده‌است که با اصلاح الگوریتم می‌توان تا حدی بر این مشکل چیره شد. در به‌کاربردن ابزارهای آماری، به نظرم مهم‌ترین چالش آماده‌سازی داده و مؤلفه‌هایی است که در داده وجود دارند و می‌توانند گمراه‌کننده باشد. برای مثال فرض کنید می‌خواهیم ویژگی‌های غیربدیهی را از یک سری داده استخراج کنیم. اگر این داده با یک روند تناوبی همراه باشد و این روند تناوبی به خوبی شناخته شده باشد در آن صورت امکان مخفی‌شدن ویژگی غیربدیهی در حضور این روند تناوبی به شدت وجود دارد. همچنین اغلب روش‌های آماری ابداع شده با فرض پیوستگی داده‌ها، توسعه یافته‌اند، این درحالی است که در آزمایش‌ها و رصدها داده‌های گسسته و اغلب نامنظم ثبت می‌شوند، لذا باید این نوع حالت‌ها مورد توجه قرار گیرد.

۱۴. در بحث کاربرد یادگیری ماشین و یادگیری عمیق چه کاربردها یا مقالات مهمی در زمینه‌ی کیهان‌شناسی و اخترفیزیک صورت گرفته‌است و نقش جامعه‌ی علمی ایران چگونه بوده‌است؟

در حوزه‌ی بین‌المللی در ابتدای گسترش ادبیات یادگیری ماشین، بسیاری از کیهان‌شناسان با موضع‌گیری‌های اغلب منفی در قبال این رویکرد و اتخاذ این استراتژی که یادگیری ماشین کمکی به افزایش بصیرت علمی ما نمی‌کند و یا در بهترین وضعیت اذعان اینکه اطلاعات مستخرج از یادگیری ماشین چیزی بیشتر از روش‌های مبتنی بر مدل‌سازی داده‌های بیزی نیست، ظاهر شدند. اما گسترش کاربست این الگوریتم‌ها و مواجهه با دستاوردهای شگرف آن، هم از حیث دقت و سرعت و هم از حیث کاربست آمارهای اهمیت بردارهای ویژگی که پیش از آن به سادگی فراهم نبود، کم‌کم جامعه‌ی علمی کیهان‌شناسی به این موضوع رغبت نشان داد و به سرعت استفاده از این رویکرد فراگیر شد. از جمله مقالات مهم در این حوزه می توان به:

Carleo, Giuseppe, et al. «Machine learning and the physical sciences.» Reviews of Modern Physics 91.4 (2019): 045002

Ball, Nicholas M., and Robert J. Brunner. «Data mining and machine learning in astronomy.» International Journal of Modern Physics D 19.07 (2010): 1049-1106.

Ball, Nicholas M., and Robert J. Brunner. «Data mining and machine learning in astronomy.» International Journal of Modern Physics D 19.07 (2010): 1049-1106.

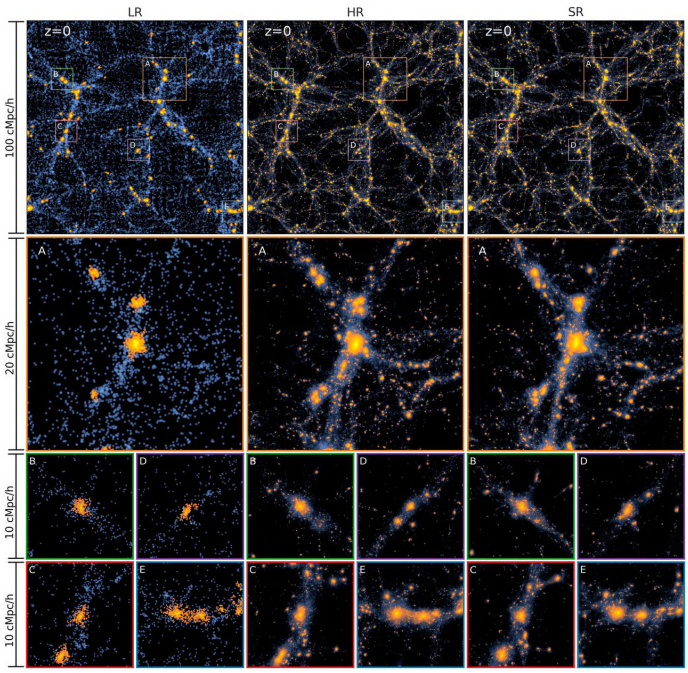
Scargle, Jeffrey D., Kamal M. Ali, and Ashok N. Srivastava. Advances in machine learning and data mining for astronomy. Ed. Michael J. Way. Boca Raton, FL: CRC Press, 2012.

Cuoco, Elena, et al. «Enhancing gravitational-wave science with machine learning.» Machine Learning: Science and Technology 2.1 (2020): 011002.

Vafaei Sadr, A., et al. «Cosmic string detection with tree-based machine learning.» Monthly Notices of the Royal Astronomical Society 478.1 (2018): 1132-1140.

اشاره کرد. در ایران نیز همراه با پیشرفت‌هایی که در دنیا انجام شده نیز، فعالیت‌های پژوهشی متعددی با تکیه بر کاربست‌های یادگیری ماشین در کیهان‌شناسی و اخترفیزیک انجام شده و در حال انجام است. برای مثال می‌توان به موضوعات زیر اشاره کرد:

- جستجو برای یافتن ردپای نواقص توپولوژیک کیهان اولیه



استفاده از هوش مصنوعی برای شبیه سازی‌های کیهان‌شناسی با قدرت تفکیک بالا[11]

خصوص را به ارمغان خواهد داشت.
مراجع و وبگاه‌های زیر نیز می‌توانند برای موضوعات پیش‌گفته مفید واقع شوند:

[1] Ntampaka, Michelle, et al. «The role of machine learning in the next decade of cosmology.» arXiv preprint arXiv:1902.10159 (2019).

[2] Ishida, Emille EO. «Machine learning and the future of supernova cosmology.» Nature Astronomy 3.8 (2019): 680-682.

[3] https://cosmostatistics-initiative.org/
(وبگاهی برای معرفی رویکردهای داده‌محور در حوزه کیهانشناسی و اخترفیزیک)

[4] Carleo, Giuseppe, et al. «Machine learning and the physical sciences.» Reviews of Modern Physics 91.4 (2019): 045002.

[5] Cui, Chenzhou, et al. «Astronomy research in big-data era.» Chinese Science Bulletin 60.5-6 (2015): 445-449.

11-https://www.pnas.org/content/118/19/e2022038118/tab-figures-data

[1] Vafaei Sadr, A., et al. «Cosmic string detection with tree-based machine learning.» Monthly Notices of the Royal Astronomical Society 478.1 (2018): 1132-1140.

[2] M Torki, H Hajizadeh, M Farhang, A Vafaei Sadr, S M S Movahed, Planck limits on cosmic string tension using machine learning, Monthly Notices of the Royal Astronomical Society, Volume 509, Issue 2, January 2022, Pages 2169–2179

[3] Movahed, Seyed Mohammad Sadegh, Alireza Vafaei Sadr, and Marzieh Farhang. «Searching cosmic strings network in the CMB.» International Journal of Modern Physics D 28.16 (2019): 2040006.

- جستجو برای یافتن ردپای امواج گرانشی تصادفی زمینه.

[۱] پویان گودرزی، پایان نامه‌ی دوره‌ی کارشناسی ارشد، دانشکده فیزیک دانشگاه شهید بهشتی، ۱۴۰۰.

سخن پایانی با دانشجویان علاقه‌مند به این حوزه؟

به نظر من، ما به‌عنوان فیزیک‌پیشه باید با توجه به مزیت‌های نسبی‌ای که در مقایسه با سایر محققان علوم کامپیوتر، علوم ریاضی و مهندسی کامپیوتر داریم با موضوع یادگیری ماشین و تحلیل داده‌های بزرگ، مواجه شویم. به‌طور مشخص استفاده از بردار ویژگی (Feature vector)، و سهم اثر هر یک در رسیدن به نتیجه می‌تواند برای فیزیک‌پیشگان مهم و حیاتی باشد. لذا می‌توانیم بر اساس دانشی که از معیارها و ابزارهای آماری و همچنین جبر عملگری (کوانتوم) داریم، الگوریتم‌های بهینه‌تری را بسازیم. به‌طور مشخص موضوع یادگیری ماشین بر اساس رویکردهای کوانتومی، می‌تواند در آینده نزدیک نقش مهمی در الگوریتم‌های رایانه‌ای ایفا کند. تحلیل توپولوژیک داده‌ها، خصوصاً آنجا که خواص سراسری داده‌ها برای ما اهمیت دارند نیز می تواند مفید واقع شود.
در سایت Kaggle نیز به‌طور مستمر چالش‌هایی مبتنی بر رهیافت‌های محاسباتی و داده‌های کلان با توجه به کیهان‌شناسی و اخترفیزیک ارائه می‌شود که شرکت در آن‌ها تجربه‌ی کار با داده‌های تصنعی در این

مصاحبه با دکتر علیرضا وفایی‌صدر

محقق پسادکتری دانشگاه ژنو سوئیس
نویسنده: آوین محبی

۱. یک مقدار از کارهای خودتان و این مسیری که در استفاده از روش‌های یادگیری ماشین و کیهان‌شناسی طی کردید و از تجربه‌هایی که داشتید بیان کنید.

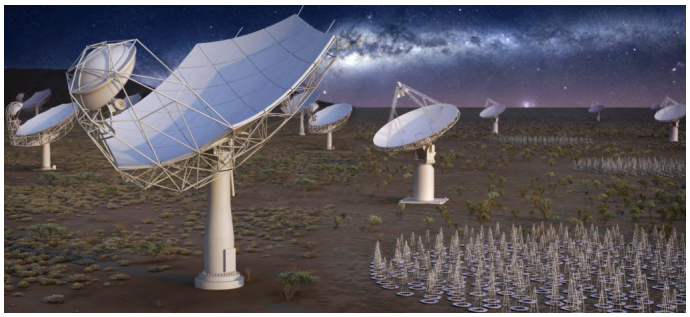
من از قبل دانشگاه هم به کامپیوتر علاقه داشتم ولی در مورد برنامه‌نویسی چیزی نمی‌دانستم. در مقطع کارشناسی‌ارشد درس کامپیوتر در فیزیک را با دکتر موحد برداشتم. تحلیل‌هایی روی داده‌های CMB انجام دادم و به برنامه‌نویسی علاقه‌مند شدم. تا ۷ و ۸ دانشگاه می‌ماندم و کدهایم را مرتب می‌کردم که بقیه هم بتوانند از آن‌ها استفاده کنند. به خاطر اینکه روی تحلیل داده کار می‌کردم، بچه‌های سیستم پیچیده گاهی به سراغم می‌آمدند. دکتر موحد استاد بین‌رشته‌ای کیهان‌شناسی و سیستم پیچیده بود و دانشجوهای دیگرشان گاهی به سراغم می‌آمدند و کلاس حل تمرین داشتم. برای همین کم‌کم به جامعه‌ی آن‌ها نزدیک شدم. به مغز و پزشکی هم علاقه داشتم. این باعث شد وارد جامعه‌ی علوم شناختی IPM شوم و با حامد سیدعلایی آشنا شدم. با هم جلسه داشتیم و راجع به تحلیل داده‌های بویایی صحبت و روی پروژه‌ای کار می‌کردیم. آنجا با ماشین لرنینگ آشنا شدم و در ابتدا با scaler شروع کردم. کم‌کم بیشتر یاد گرفتم و در اواسط دوره‌ی دکترا به ویزیت در سوئیس رفتم (دکترا شهید بهشتی بودم). در گروه دانشگاه ژنو که بودم، یک بسته شبیه‌سازی داشتند که با زبان سی نوشته شده‌بود. شروع به کار کردن با آن کردم. اواسط ویزیت به من پیشنهاد شد که روی anomaly detection با شبکه‌ی عصبی هم کار کنم. عبارت شبکه‌ی عصبی را زیاد شنیده‌بودم ولی چیزی در مورد آن نمی‌دانستم. کمی راجع به آن خواندم و کمی رویش کار کردم و نتایجی هم گرفتیم. همزمان که ویزیت بودم، روی تز دکترا هم داشتم کار می‌کردم که روی استفاده از یک سری ابزار محاسباتی برای تشخیص‌دادن ریسمان‌های کیهانی بود و مستقل از شبیه‌سازی ژنو بود. قرار بود ۶ ماه سوئیس باشم و ۶ ماه در استرالیا با گروهی که با SKA کار می‌کنند همکاری کنم.



دکتر علیرضا وفایی‌صدر

در مورد SKA بیشتر توضیح می‌دهید؟

پروژه‌ایست که بلندپروازانه برای ساختن یک تلسکوپ رادیویی خیلی بزرگ بین حدود ۲۰ کشور تعریف شد و کشورهای زیادی روی آن سرمایه‌گذاری کرده‌اند. خیلی از تلسکوپ‌های رادیویی که الان اسمشان را می‌شنویم، precursor برای این تلسکوپ هستند. یعنی در ابعاد کوچک‌تر ساخته شده‌اند که بررسی شود تلسکوپ اصلی چگونه باید ساخته شود.



SKA[1]

بنا بود در استرالیا و آفریقای جنوبی به‌طور مشترک ساکن شود. گروه ascap در استرالیا و گروه meerkat در آفریقا روی آن کار می‌کردند. مسئله‌ای در anomaly detection بود که چطور از بین تعداد بالایی جسم، غیرنرمال‌ها را پیدا کنیم و چالش Widefield ouTlier Finder (WTF) تعریف شد. شروع به کار روی آن چالش کردم و قرار بود بعد

1-https://www.skatelescope.org/news/ska-statement-on-satellite-constellations/

از سوئیس به استرالیا بروم تا با گروه ascap کار کنم اما به خاطر مشکل ویزا، کنسل شد و پیشنهاد شد به آفریقا بروم. خیلی اتفاقی رفتم و آنجا با Bruce Bassett آشنا شدم. کم‌کم به نتایجی رسیدم و روی پروژه‌ی دیگری هم شروع به کار کردم. این پروژه، point source detection بود. در عکس‌های رادیویی که خیلی بزرگ و برای مثال ۳۲۰۰۰ در ۳۲۰۰۰ پیکسل هستند، ممکن است نزدیک به یک میلیون جسم باشد. بنابراین به سیستمی نیاز است که از میان نویز، آن اجسام را پیدا کند و به عنوان عکس‌های کوچک برگرداند. نتایج هر دو پروژه امیدوارکننده بود و تیم هم، تیم خوبی بود. مصداق قرارگرفتن در زمان درست در جای درست بود. بعد از سالی که بخشی از آن را در سوئیس و بخشی را در آفریقای جنوبی گذراندم، به ایران برگشتم ولی همکاری با تیم Bruce Bassett را ادامه دادم و کار را تمام کردیم.

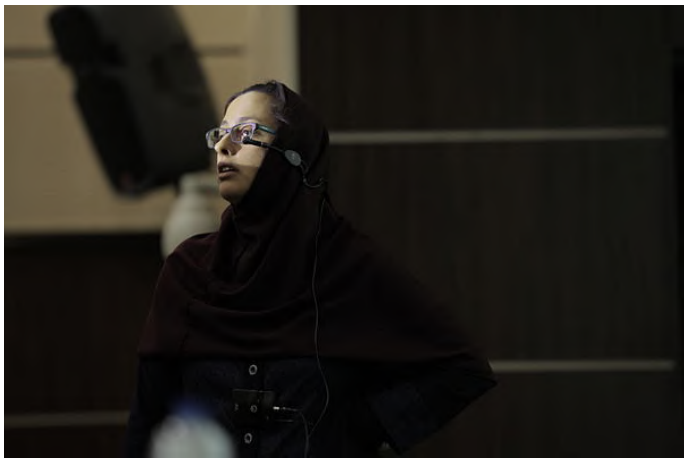
۳. در مورد Bruce Bassett بیشتر توضیح می دهید؟

خیلی آدم جالبی است و از کسانی است که تأثیر زیادی روی من گذاشته‌است. با اینکه دکترای fundamental physics دارد اما خیلی به تکنولوژی علاقه‌مند است و data science و AI کار کرده‌است. با کیهان‌شناسی به‌سمت کارهای مرتبط با AI رفته‌است. علاوه بر اینکه scientist خوبی است، بسیار مدیر خوبی است و از او در این مورد خیلی یاد گرفته‌ام.



Bruce Bassett

خوب است همین جا از چند نفر که به من اعتماد کردند و باعث رشد من شدند نام ببرم. اولین فرد دکتر موحد است که از من حمایت کرد و از نوع برخوردش با بقیه تأثیر گرفته‌ام و خودم هم سعی کرده‌ام در ارتباط با اطرافیانم به‌کار گیرم.
دومین نفر Bruce Bassett است که پیش‌تر گفتم و سومین نفر خانم دکتر فرزان است. زمانی که اولین پسادکترایم را گرفتم، به گروه دکتر شیخ جباری در IPM رفتم و خانم دکتر فرزان به من اعتماد کردند و با اینکه data science کار می‌کردم من را در گروه فیزیک پذیرفتند. این سه فرد، علی‌الخصوص مورد اول و دوم روی شخصیت و نوع مدیریت من تأثیر زیادی داشتند.



دکتر یاسمن فرزان

قبل از اتمام دکترا، SKA دوباره از من دعوت کرد و دو ماه به آفریقا رفتم. پس از آن به ایران برگشتم و دفاع کردم. نمی‌خواستم به خاطر سربازی gap آکادمیک ایجاد شود به همین خاطر برای پسادکترا اپلای کرده بودم. برای گروه فیزیک و کامپیوتر و اخترفیزیک IPM درخواست فرستادم و هر سه خوب برخورد کردند. بعدها با هر سه گروه همکاری کردم اما در آن زمان چون گروه فیزیک زودتر از دو گروه دیگر موافقتش را اعلام کرد، رفتم فیزیک و نزدیک یک سال پسادکترا طول کشید. آزادی عمل بیشتری داشتم. هم با دکتر موحد و هم بروس بست پروژه ادامه دادم و روی data science بیشتر تمرکز کردم. نتیجه‌اش این شد که یک ورکشاپ دیتاساینس در IPM برگزار کردم. همینطور به‌صورت جدی‌تر وارد دنیای پزشکی شدم. در دوران کرونا به یکی از دوستانم برای کارهای محاسباتی در مقالات پزشکی کمک کرده‌بودم اما کار AI در پزشکی نکرده‌بودم.
بعد از اتمام ورکشاپ، coadvisor یک سری دانشجوهای علاقه‌مند از علوم پزشکی ایران شدم و رسما وارد این حوزه شدم. کم‌کم دانشجوهای بیشتری آمدند و این شروع راه‌اندازی AI medic بود.

۴. در مورد AI medic هم توضیح کوتاهی می‌دهید؟

وارد حوزه‌ی AI شده بودم و به‌نظرم فضای هوش مصنوعی ایران بی‌نظم بود. مسیر مشخصی برای یادگیری و شروع به کار در این حوزه نبود. معلوم نبود کسی که خود را data scientist می‌نامید چه قابلیتی داشت. با آقای کریمی که در سرمایه‌گذاری استارت‌آپ‌ها کار می‌کرد حرف زدیم که یک startup studio راه بیندازیم که بیشتر از یک ورکشاپ آکادمیک باشد و به کاربرد برسد. ایده در ابتدا کلی بود. با افراد مختلف صحبت کردیم و قرار شد جزئی‌تر به بررسی آن بپردازیم. به توافق رسیدیم که آن را در زمینه‌ی پزشکی پیش ببریم. با دانشجویانی که با من کار می‌کردند یک تیم تشکیل شد و این تیم کم‌کم بزرگ شد و تغییر کرد. من هم آنجا advisor بودم.
بعد از سربازی، از ژنو اکسپت گرفتم. یک سال و نیم ژنو بودم و هنوز این پسادکترای من تمام نشده‌است. در فیزیک کارهای زیادی می‌توان انجام داد اما حس کردم همزمان نمی‌توانم همه را انجام بدهم و نمی‌توانستم روی هر دو موضوع تمرکز کنم برای همین تصمیم گرفتم روی پزشکی تمرکز کنم و حداقل به‌طور مستقیم با جامعه‌ی فیزیک در تماس نباشم.

۵. دلیل محبوبیت متدهای لرنینگ در کیهان‌شناسی در سال‌های اخیر (یا محبوبیت لرنینگ به‌طور کلی و نه لزوماً در زمینه‌ی کیهان‌شناسی) چیست؟

چند دلیل مختلف برای این مسئله وجود دارد. مثل جسمی است که با چند طناب کشیده می‌شود. یکی از دلایل آن این است که فیزیک تئوری همیشه موضوعات فوق‌العاده‌ای برای کار کردن ندارد و هر چند وقت یک بار موضوعی مورد توجه است. همیشه سؤال است موضوع یا حرفی که مورد توجه قرار بگیرد در هر حوزه چیست؟ به عنوان آکادمیسین صرف، ماشین لرنینگ این فضا را باز کرد که کارهای عجیبی بکنیم که مورد استقبال و توجه قرار بگیرد. حتی در حوزه‌های دیگر مثل اقتصاد هم استفاده از ماشین لرنینگ مورد توجه قرار می‌گیرد چون جدید است.
دلیل دوم این است که می‌توان به موضوعاتی، کمی علمی‌تر نگاه کرد. ماشین لرنینگ به ما پیشنهاد مدل‌سازی‌های پیچیده‌ای می‌دهد که قبلاً نمی‌توانستیم ببینیم و ابزار قدرتمندی است. کاربردی است و در مهندسی هم بسیار کاربرد دارد و می‌توان کارهایی که قبلاً نمی‌توانستیم را انجام دهیم.
از آنجایی که زندگی را راحت می‌کند هم می‌توان از آن پول درآورد. کسانی که با ماشین لرنینگ کار می‌کنند و از آن درآمد کسب می‌کنند معمولاً روی آموزش آن سرمایه‌گذاری می‌کنند و به این ترتیب چرخه‌ای است که خود را بازتولید می‌کند.
به‌طور کلی در حوزه‌هایی مثل کیهان‌شناسی، پزشکی و اجتماعی که داده‌های زیادی داریم چاره‌ای نیست جز اینکه از این ابزارها استفاده کنیم.

۶. آیا هوش مصنوعی می‌تواند در کیهان‌شناسی غالب شود و جای یک کیهان‌شناس را بگیرد؟ یا در حوزه‌های دیگر، برای مثال این سؤال در پزشکی خیلی مطرح می‌شود که آیا هوش مصنوعی می‌تواند جای یک پزشک را بگیرد؟

من در پاسخ این سؤال معمولاً از این مثال استفاده می‌کنم. قبلاً برای نگهداری از یک خانه‌ی ۲۰۰ متری آدم‌های زیادی درگیر بودند. جارو و خاک‌انداز نیاز بود. برای گرما هیزم نیاز بود و برای همین شغل هیزم‌فروش وجود داشت. با آمدن جاروبرقی، گاز و ابزارهایی از این قبیل، کارها راحت‌تر می‌شود و افراد کار کم‌تری انجام می‌دهند. اما یه این معنی نیست که افراد بیکار می‌شوند. بلکه به کارهای سطح بالاتر می‌پردازند. کارها دقیق‌تر انجام می‌شود و افراد، سختی کمتری می‌کشند. به‌طور کلی، در طول زندگی بشر از کارهای دستی به کارهای فکری رفته‌است. برای مثال بحث metaverse و omniverse مطرح می‌شود که می‌توان صرفاً به چیزی فکر کرد و ربات‌ها آن را برای ما می‌سازند. یعنی کم‌کم از کارهای عملی به سمت کارهای مدیریتی می‌رویم.
جایگزینی افراد با هوش مصنوعی مخصوصاً در موارد حساسی مثل پزشکی خیلی آهسته صورت خواهدگرفت اما حتمی است. سطح صفر زندگی انسان پیشرفت می‌کند همان‌طور که اینترنت الان سطح صفر زندگی است اما پنجاه سال پیش نبود. این مسئله لزوماً باعث نمی‌شود بشر به خطر بیفتد.

۷. کمی درمورد پیشرفت‌های فعلی روش‌های هوش مصنوعی در کیهان‌شناسی بگویید. به نظرتان جامعه‌ی فعلی کیهان‌شناسی استفاده‌ی درستی از این روش‌ها می‌کند؟

الان خیلی استفاده می‌کنند. در چالش SKA یک و دو. همین‌طور در Hirax.

۸. در مورد Hirax هم کمی توضیح می‌دهید؟

شبیه SKA است ولی تلسکوپ کوچک‌تری است. SKA بیشتر روی خود اجسام تمرکز دارد ولی Hirax بیشتر به توزیع آن اجسام اهمیت می‌دهد. Hirax هم در آفریقای جنوبی و نزدیک meerKat است. فاند این پسادکترای من از طرف Hirax است. آن‌ها هم قرار بود تیم هوش مصنوعی داشته‌باشند و من آن را راه‌اندازی کنم ولی من از حوزه‌ی کیهان‌شناسی به پزشکی رفتم.
اگر به آرکایو بروید و کلمه‌ی ماشین لرنینگ را سرچ کنید، تعداد رکوردها هر سال به‌صورت نمایی زیاد شده‌است. هم SKA و هم Hirax پروژه‌هایی بر پایه‌ی هوش مصنوعی دارند. معنی آن این است که افراد زیادی از آن استقبال کرده‌اند و هرجایی تلاش شده از آن استفاده شود. طبیعتاً در این جامعه، کیفیت کارها متفاوت است. برای مثال ممکن است کسی با حل یک مسئله خلق ارزش کند ولی کسی مقاله‌ای منتشر کند که چند روز بعد فراموش شود. همه‌ی آدم‌هایی که به این حوزه ورود می‌کنند درست کار نمی‌کنند ولی در تیم‌های قوی و کارهای جدی، همه می‌دانند که هوش مصنوعی چیزی است که باید گروهی برای آن تشکیل دهند و مهم است.



Hirax[2]

در CERN هم تیمی به علوم کامپیوتر اختصاص داده شده‌است. به‌طور کلی در همه‌جای فیزیک و به‌طور خاص در کیهان‌شناسی که داده‌ی زیادی داریم هوش مصنوعی مهم است و با اینکه آدم‌هایی که در این حوزه کار می‌کنند زیاد هستند اما فرصت‌های زیادی برای انجام کارهای جالب وجود دارد. اما به این معنی نیست که هرکس کمی کار کند ایده‌ای بسیار تکان‌دهنده می‌تواند بدهد. مشکلاتی مثل data fabrication هم هست که البته در فیزیک کمتر است و دارد کم می‌شود.

2-https://www.itweb.co.za/amp/content/j5alr7QlQ8YvpYQk

۹. دو مسئله‌ی به‌صورت خاص در مورد هر استفاده‌ای از هوش مصنوعی پررنگ است. یکی بالا بردن سرعت و دقت پیش‌بینی‌پذیری و دیگری شهود پیدا کردن در مورد فرایندهای فیزیکی و قوانین بنیادی با یادگیری ماشین. به نظر شما به کدام یکی از این‌ها بیشتر پرداخته می‌شود؟ اصلا امکانش هست که یادگیری ماشین علاوه بر پیش‌بینی به ما شهود فیزیکی هم بدهد؟

می‌توان تشبیه کرد به اینکه ما دو دسته آدم داریم. یکی آدم‌های pragmatic که به انجام شدن یک عمل بیشتر اهمیت می‌دهند و دیگری کسانی که بنیادی و به چرایی مسائل فکر می‌کنند. ماشین لرنینگ هر دوی این‌ها را دارد. اولی پررنگ‌تر است و مسئله در واقع یک optimization problem برای بالا بردن عملکرد است. خیلی از جاها ماشین لرنینگ اثبات کرده‌است که برای این مسئله می‌تواند مفید باشد و نتیجه بدهد. جاهای زیادی هم برای این کار، کاربرد دارد مخصوصاً در فیزیک. بحث بعدی این است که مهم نیست که این کار را می‌توان به خوبی انجام داد. سؤال این است که چرا می‌توان این کار را به خوبی انجام داد؟ در این بخش مهم نیست که یک پدیده در طبیعت اتفاق افتاده‌است بلکه سؤال این است که چرا اتفاق افتاده است؟ آدم‌ها کم‌تر روی این بخش دارند کار می‌کنند. جدیدتر و چالشی‌تر است اما دارد کار می‌کند و این‌گونه نیست که بی‌نتیجه باشد. برای مثال من خودم روی یک تحقیق کار می‌کنم که در طول زمان در configuration جمجمه مشکلی پیش می‌آمده. افرادی که این مشکل برایشان پیش می‌آمده deformation های مختلفی را در نواحی مختلف جمجمه داشتند و در طول ۱۰۰، ۱۵۰ سال گذشته پزشکان در تصویربرداری‌هایی که انجام می‌دادند سعی کردند حدس بزنند که کدام ناحیه‌ها نشان می‌دهد واقعاً این مشکل وجود دارد یا خیر. نتایج را در ماشین لرنینگ وارد کردیم و ناحیه‌هایی مشخص شد که احتمال می‌رفت deform شده بود. وقتی آن را با نتایجی که طی ۱۰۰، ۱۵۰ سال به دست آورده بودند پزشکان، هم‌خوانی داشت. یعنی ماشین توانست با ۳۰۰۰، ۴۰۰۰ داده به اندازه‌ی ۱۰۰ و خورده‌ای سال تجربه را نتیجه‌گیری کند. این مسئله اهمیت دارد و می‌توانند در فیزیک هم با استفاده از آن در مواردی شهود پیدا کرد. مثلاً کدام پارامتر این مسئله دارد بیشتر تغییر می‌کند که یک پدیده اتفاق می‌افتد.

۱۰. اهم تلسکوپ‌های فضایی و زمینی که در دهه‌های حاضر قرار است وارد فاز عملیاتی شوند کدام مأموریت‌ها و متعلق به کدام سازمان‌ها است؟ چه چیزی هر کدام از این مأموریت‌ها را متمایز و جالب توجه می‌کند؟

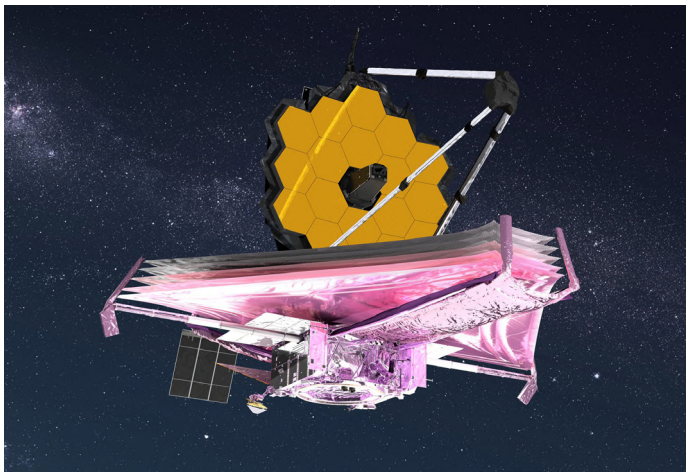
اولین چیزی که در کیهان‌شناسی قابل توجه بود رصدهای منجر به قانون هابل بود. بعد از آن داده‌های CMB که هنوز هم در آن سرمایه‌گذاری می‌شود برای مرحله‌ی چهارم ولی خیلی خبر بزرگی از آن در نمی‌آید. احتمال می‌رود انقلاب بعدی مربوط به رصدهای رادیویی باشد زیرا به ما اطلاعاتی از جایی و دوره‌ای از عالم می‌دهند که قبلاً یا اطلاعاتی نداشتیم یا محدود بود. انتظار می‌رود خبرهای داغ و لرزاننده‌ای در این زمینه باشد و بیشتر سرمایه‌گذاری‌ها اینجا انجام می‌شوند. بزرگ‌ترین آن‌ها SKA است که تعداد زیادی هم precursor دارد و هنوز در حال ساخته‌شدن هستند. از تعداد کم و بخش کم پروژه شروع می‌کنند و کم‌کم نتایج را تحلیل می‌کنند و بیشتر پیش می‌روند. Hirax هم پروژه‌ی دیگری در این زمینه است.

رصدهای دیگری که هست، رصد تابش‌های انرژی بالا مثل گاما و ایکس ری را رصد می‌کنند. رصدهایی که سعی می‌کنند اطلاعاتی در مورد ماده‌ی تاریک یا در حوزه‌ی particle physics کسب کنند؛ برای مثال، راجع به نوترینوها. انتظار می‌رود امواج گرانشی هم سروصدا کنند و اخبار زیادی راجع به آن خواهد بود.

۱۱. اگر ممکن است راجع به GW کمی توضیح دهید.

من در این حوزه زیاد کار نکردم. به‌طور کلی رصدهایی است که داده‌هایش به فرم سری زمانی است. الگوهایی که در آن سری زمانی رخ می‌دهند می‌توانند بازگوکننده‌ی توزیع آن باشد. دوتا از چالش‌های آن، داشتن نویز زیاد و مهم‌بودن سرعت است. روش‌هایی باید استفاده کرد که الگوها را بتوانند تشخیص بدهند.

۱۲. داده‌هایی که توسط تلسکوپ‌های فضایی (JWST) و زمینی (SKA) به دست می‌آید چه تأثیری در نوع نگاه ما به جهان و روش‌های انجام پژوهش‌های نجومی خواهند گذاشت؟ در این شرایط، مفهوم کار رصدی و نجومی (تئوری) چگونه بازتعریف می‌شود؟



James Webb Space Telescope (JWST)[3]

اولین تأثیر این است که بخشی از عالم را تصور کرده بودیم. بر اساس تئوری و تصور هستند. برای مثال از ابتدای عالم از CMB اطلاعاتی داریم و از بخش‌هایی با SDSS اطلاعات داریم. ولی مثلاً بین ردشیفت ۳ و ۲۰۰ اطلاعاتی نداریم که چه اتفاقی افتاده‌است. اطلاعات خیلی کمی داریم و علامت سؤال بزرگی وجود دارد. مأموریت مقدس فیزیک این است که مشاهده کنیم و قانون بسازیم. دومین تأثیر این است که قبل از CMB را بفهمیم. ممکن است رصدهایی که در particle physics صورت می‌گیرد کمک کند. خیلی مهم است از این نظر که هولستیک ویو داشتیم و انگار از پشت یک شیشه‌ی کثیف داشتیم نگاه می‌کردیم. این شیشه کم‌کم تمیز می‌شود و نگاه ما به‌مرور دقیق می‌شود. این قابلیت را داریم که اجسام را ببینیم و تحول individual این اجسام را بررسی کنیم. ممکن است اگر اجسام غیرعادی و رفتارهای غیرعادی زیادی ببینیم مجبور باشیم بخش‌هایی از فیزیک را دست‌کاری کنیم. این قابلیت را خواهیم داشت که تئوری‌هایی که صرفاً کار می‌کردند را حالا امتحان کنیم و خیلی از آن‌ها حذف خواهند شد.

در مورد بخش دوم سؤال، طبیعتاً این باعث می‌شود کسانی که کار رصدی و تئوری می‌کنند نزدیک‌تر شوند. برای مثال وقتی اطلاعات COBE بود حرف‌هایی درمورد early universe زده می‌شد و تئوری‌هایی بود. هرچه اطلاعات بیشتر شد، کم‌کم تئوری‌هایی حذف شدند و فضا تنگ‌تر شد. کار تئوری و رصدی نزدیک‌تر شد. به‌طور کلی باعث می‌شود طیف جامعه‌ی فیزیک یک‌دست‌تر و منظم‌تر بشود.

۱۳. به نظر شما چرا صرف هزینه و ایجاد این تلسکوپ‌ها و دریافت داده‌های با این وضوح و کیفیت اهمیت دارد؟ از نظر سیاست‌گذاری کلان و سیاست‌گذاری علمی، چه دلایلی باعث تعریف این مأموریت‌ها می‌شود؟

3-https://www.space.com/james-webb-space-telescope-first-observing-targets

دلایل متعددی وجود دارد. یکی از آن‌ها نگاه کنجکاوانه‌ی بشر است که از ابتدا به دانستن تمایل داشته‌است. مثل داستان زمان، از تأثیرات فیزیک است که درکمان نسبت به زمان چندین بار عوض شده‌است.
وقتی در مورد بنیان جهان و فهمیدن در موردش حرف می‌زنیم، معمولاً روی فیزیک بنیادی سرمایه‌گذاری می‌شود چون جواب سؤال‌هایی را می‌دهد که بعداً از آن خیلی می‌توان استفاده کرد.
علاوه بر آن، فارغ از نتایج، هرکدام از این پروژه‌ها روندشان کمک به پیشرفت تکنولوژی می‌کند و مرزهای آن را عوض می‌کنند. برای مثال CERN کمک شایانی به پیشرفت اینترنت کرده‌است. حتی اگه نتیجه‌ای از CERN نمی‌گرفتیم، باز هم دستاوردهایی از این قبیل داشت. مثل زمانی است که هواپیماها و ساخت آن‌ها تأثیر زیادی در پیشرفت کامپیوترهای شخصی و کوچک‌شدن اندازه‌ی آن‌ها داشتند! برای همین روی این پروژه‌ها سرمایه‌گذاری می‌شود.
همچنین ادعای دانش ذاتاً به انسان‌ها حس غرور می‌دهد. مثال آن رقابت روسیه و آمریکا بر سر زودتر رسیدن به ماه است و برای همین طبیعتاً روی این موارد سرمایه‌گذاری می‌شود.

۱۴. چه چیزی باعث می‌شود یک مجموعه‌ی داده را ابرداده یا بیگ دیتا بنامیم؟

این جواب را از بروس بست یاد گرفتم و با توضیح خودم این‌گونه بیان خواهم کرد: اگر من به شما بگویم می‌خواهم یک فیلم با حجم سه گیگ به شما بدهم تعجب نخواهید کرد. اما اگر بخواهم یک عکس سه گیگابایتی به شما بدهم، قطعاً تعجب می‌کنید. جایی که اندازه‌ی داده نسبت به انتظارمان بزرگ‌تر شود، به آن ابرداده می‌گوییم. نمی‌توان به‌خودی‌خود گفت که ده گیگ ابرداده است یا دو گیگ ابرداده است. این مسئله با توجه به پیچیدگی، انتظارمان، چیزی که در آن داده به دنبالش هستیم و اندازه‌ی آن به همراه هم تعیین می‌شود. در واقع بیگ دیتا یک چالش است. برای مثال اگر یک عکس سه گیگابایتی از یک منظره داشته باشیم و بخواهیم تعداد درخت‌ها را بشماریم، پیچیده است چون کیفیت و جزییات عکس بالا هستند. برای کار با ابرداده، باید به سراغ ابزاری برویم که برای کار با آن مناسب است. دلیل به‌وجودآمدن چالش ابرداده در حوزه‌ی رصد، به‌طور کلی دو مورد است. اول اینکه از نظر ساخت تکنولوژی رصد (مثلاً ساخت سنسور) پیشرفت کرده‌ایم و تعداد تلسکوپ‌ها و رصدگرها زیاد شده‌است. این باعث می‌شود اطلاعات زیادی دریافت کنیم. علاوه بر کثرت، عمقی که می‌توانیم به آن دسترسی پیدا کنیم هم افزایش یافته‌است. زیرا با پیشرفت تکنولوژی رصد، کیفیتی که می‌توانیم به آن دست پیدا کنیم نیز افزایش یافته‌است. این دو مورد باعث پدیدآمدن چالش بیگ دیتا در رصد شده‌اند.

۱۵. برای تحلیل ابرداده‌ها چه ابزار و روش‌هایی وجود دارد؟ می‌توان از روش‌های قدیمی استفاده کرد؟ چه تخصص‌هایی برای این تحلیل‌ها در کنار منجمان قرار می‌گیرند؟

به‌طور کلی دو دسته ابزار نیاز داریم. یکی ابزار تکنیکال شامل برنامه‌نویسی و کامپیوتر که برای اجرای کار هستند. یکی ابزار تئوری مثل ریاضیات و آمار که افرادی روی آن‌ها کار می‌کنند. معمولاً برای بخش برنامه‌نویسی از پایتون و پکیج‌های آن استفاده می‌شود که به‌طور کلی عملکرد قابل‌قبولی دارند. در برنامه‌نویسی دو زمان برای ما اهمیت دارد. یکی زمانی که طول می‌کشد تا برنامه را بنویسیم که پایتون عملکرد خوبی دارد در این مورد و دیگری زمانی که برای اجرا صرف می‌شود که پایتون در این مورد معمولی است. برای همین در کل، عملکرد قابل قبولی دارد.
مرز خاصی بین استفاده از ابزار قدیمی و جدید وجود ندارد. صرفاً از ابزار ساده شروع می‌کنیم و سعی می‌کنیم با آن مسئله و مشکل را حل کنیم. وقتی نتیجه‌ای نمی‌گیریم، کم‌کم سراغ ابزار پیچیده‌تر می‌رویم. برای مثال وقتی می‌خواهیم یک بیماری مرتبط به قند خون را تشخیص دهیم می‌توان با اندازه‌گیری فشار خون، توزیع داشتن یا نداشتن بیماری با قند خون‌های مختلف را به دست آورد و فهمید بیماری در قند خون تفاوتی ایجاد می‌کند یا خیر. اما این کار را به همین نحو نمی‌توان با عکس مغز بیمار انجام داد و ابزار دیگری می‌خواهیم.
تخصص‌هایی که برای استفاده از این ابزارها نیاز است شامل آمار می‌شود که ممکن است خود منجم آن را بلد باشد. همچنین تئوری مدل‌سازی و متخصصینی برای تعیین نوع داده و نحوه‌ی ذخیره‌سازی، مهندسین پایگاه داده در این فرایند حضوردارند. به افرادی که کمی علوم کامپیوتر بلد باشند برای اینکه بتوانیم برنامه‌ها را با کارایی بالا و کافی نوشت نیاز است تا بتوانیم از سخت‌افزار استفاده‌ی درستی بکنیم. داده‌ها process می‌شوند و برای تحلیل و تفسیر با استفاده از ماشین لرنینگ آماده هستند.

۱۶.این روزها در مقالات حوزه‌ی علم، عبارت هوش مصنوعی و ماشین لرنینگ را زیاد می‌بینیم. مفهوم این عبارت‌ها چیست؟

هوش مصنوعی بخشی قدیمی در علوم کامپیوتر است و چیز جدیدی نیست. در این بخش تلاش می‌شود کارهای آدم را کامپیوتر انجام دهد. تکنیک‌های کلاسیکی برای این کار بوده و کم‌کم تکنیک‌هایی وارد حوزه شده‌اند، طوری که انگار ماشین خودش دارد یاد می‌گرفت. می‌توان گفت هوش مصنوعی مثل سلاح و ماشین لرنینگ مثل تفنگ است، یک سلاح قوی.

۱۷. منظور ما از هوشمندبودنِ یک سیستم و یاد گرفتن آن چیست؟

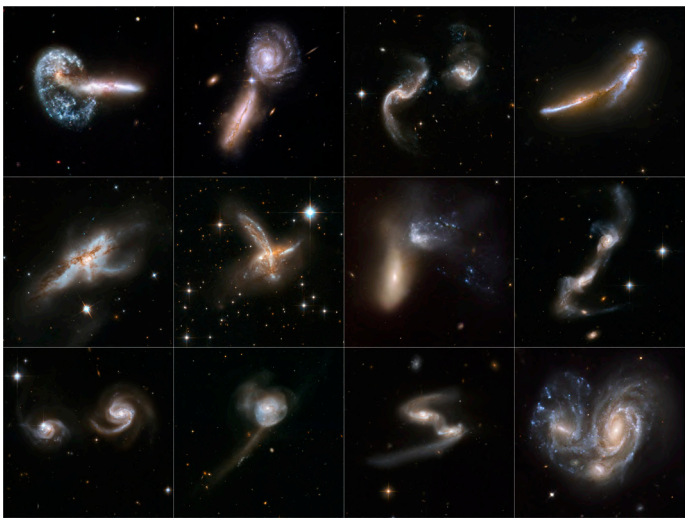
فرض کنید یک مدل ریاضی خیلی پیچیده داریم که پارامترهای زیادی دارد. به آن یک ورودی می‌دهیم. مثلاً عکس سیاه و سفید گربه یا سگ. این مدل، روابطی ریاضی را روی این ورودی‌ها اعمال می‌کند. مثلاً پیکسل اول را با دوبرابر پیکسل دوم جمع می‌کند و روابط ریاضی دیگر، تا اینکه به یک عدد برسد. مثلاً صفر یا یک. قرارداد می‌کنیم که صفر، گربه باشد و یک، سگ باشد. در ابتدا پارامترهای این عملیات ریاضی را به‌صورت رندوم تعیین می‌کنیم که مثلاً هر عدد را دو برابر کنیم یا پنج برابر کنیم. بعد، وقتی نتایج غلطی می‌گیریم (مثلاً برای عکس سگ، صفر نتیجه می‌شود) این پارامترها را به نحوی عوض می‌کنیم که سگ یا گربه بودن آن عکس را درست تعیین کند. مثل فرایند آزمون و خطا است. با عوض‌کردن پارامترهای این مدل ریاضی، انگار ماشین دارد یاد می‌گیرد. این اتفاق آرام‌آرام رخ می‌دهد.

۱۸. روش‌های یادگیری ماشین چه تفاوتی با الگوریتم‌های سنتی دارند و برای چه کارهایی مناسب‌تر هستند؟

وقتی مسئله‌ی پیچیده‌ای داشته باشیم، الگوریتم دیگری جز ماشین لرنینگ نداریم! اصلاً با الگوریتم‌های سنتی نمی‌توان به این نحو به سراغ آن مسئله‌ی پیچیده رفت. ماشین لرنینگ در این شرایط، تنها انتخاب خواهد بود و قابل‌مقایسه نیست. یکی از تفاوت‌های الگوریتم کلاسیک و ماشین لرنینگ را می‌توان قابلیت بهترشدن و بهبودپذیری ماشین لرنینگ دانست. الگوریتم سنتی hard-coded است و این قابلیت را ندارد.

۱۹. در چند سال اخیر استفاده از یادگیری ماشین برای حل مسائل نجومی گسترش یافته‌است. اگر بخواهید این موارد را در چند دسته‌ی کلی طبقه‌بندی کنید چه دسته‌هایی را تشکیل می‌دهید؟

اتفاقاً راجع به این موضوع یک سخنرانی داشتم. مواردی که الان به ذهنم می‌رسد و می‌توانم نام ببرم یکی دسته‌بندی یا classification است که بدیهی‌ترین است. می‌توان از مثال‌های آن Galaxy Zoo را نام برد که ماشین تشخیص بدهد کهکشان برای مثال مارپیچی است یا irregular یا نوع دیگری. بخش دیگر regulation است که می‌توان parameter estimation انجام داد. مثلاً تعداد بازوی کهکشان یا ردشیفت و خروج از مرکز هرکدام را محاسبه کرد. تز دکترای من هم مثالی برای آن است. موضوع آن cosmic string detection است و بعد از پاسخ به اینکه هست یا نیست، تعیین مقدارش بود. کار دیگر، شبیه‌سازی است که کاری کنیم ادای بعضی چیزها که دوست داریم را دربیاورد. قبلاً خیلی سخت‌تر بود. مثالش شبیه‌سازی عکس‌های کهکشان است. کاربرد دیگر، بالا بردن سرعت محاسبات است که به مسیر شبیه‌سازی هم کمک می‌کند. گاهی اوقات ماشین می‌تواند یک مسئله را مدل کند. برای مثال اگر قرار است معادله‌ای را صدبار حل کند و هر بار ده ثانیه طول بکشد، با مدل کردن آن، هربار ده به توان منفی چهار ثانیه طول بکشد و چند مرتبه‌ی بزرگی کمتر خواهد شد.



Galaxy Zoo یک پروژه نجوم آنلاین است که از عموم مردم دعوت می کند تا در طبقه بندی بیش از یک میلیون کهکشان کمک کنند. Galaxy Zoo یک همکاری بین دانشگاه Oxford، دانشگاه Portsmouth، دانشگاه Johns Hopkins و Fingerprint Digital Media، Belfast است.[۴]

4-https://en.wikiversity.org/wiki/Galaxy_Zoo

۲۰. آیا می‌توان از روش‌های یادگیری ماشین مورد استفاده در علوم دیگر برای حل مسائل نجومی (و برعکس) استفاده کرد؟ چه نمونه‌هایی از این کار وجود دارد؟

جواب این سؤال به‌طور قطع مثبت است. خودم شاهد این مورد بین پزشکی و کیهان‌شناسی بوده‌ام. درواقع می‌توان از همان تکنیک یکسان استفاده کرد ولی روی داده‌ی متفاوت. برای همین است که وقتی کسی به چند حوزه آشنا باشد، خوب است چون ابزارها و تکنیک‌هایی که در حوزه‌ی دیگر برای روبه‌رو شدن با مسائل مشابه استفاده شده را دیده است. خودم در کنفرانسی شرکت کردم با همین موضوع که در دانمارک برگزار شد و اسمش When the Earth Meets the Sky بود. همین‌طور سری سمینارهای From Cells to Galaxies در این ارتباط وجود دارند. از تکنیک‌های نجوم رادیویی که برای بازسازی تصویر و کم‌کردن نویز استفاده می‌شود در تصویربرداری پزشکی هم از لحاظی به همین نحو استفاده می‌شود. همین‌طور مدل‌های طبقه‌بندی مشترک وجود دارند.

۲۱. آیا می‌توان به داده‌های شبیه‌سازی و مأموریت‌های فضایی به راحتی دسترسی پیدا کرد؟ چطور می‌توان با آن‌ها کار کرد؟

مقدار زیادی open data وجود دارد که task خاصی هم برای آن‌ها تعریف نشده‌است، مثل داده‌های ماهواره‌ی planck که در سایت آن در دسترس عموم قرار گرفته‌است. به نظر من برای شروع کار، بهترین راه این است که داخل چالش‌هایی مثل Galaxy Zoo شرکت کنیم که برای دسته‌بندی کهکشان‌ها از روی عکسشان است. این چالش‌ها هم دیتایشان در دسترس است هم تسک تعریف‌شده دارند و افراد زیادی روی آن کار کرده‌اند. چالش‌هایی از این قبیل باز هم هستند مثل PLAsTiCC. همچنین چالش اول SKA هم در دسترس است. این چالش‌ها از آنجایی که تسک تعریف‌شده دارند و می‌دانیم می‌خواهیم چه کار کنیم و هدفمان چیست، خوب هستند.

۲۲. برای کسی که علاقه‌مند است بیشتر بداند یا شروع به کار جدی در این زمینه بکند چه توصیه‌ای دارید؟

باید دست‌به‌آچار بود. این یک توانایی است که بتوان با نگاه‌کردن به کد دیگران یا با دیدن کد زدن بقیه، یاد بگیریم و سپس سعی کنیم مسائل را مثل آن‌ها حل کنیم. این اتفاق می‌افتد که ما با دیدن ۵۰۰ کد مختلف، با ۵۰۰ دیدگاه مختلف به مسائل نگاه خواهیم کرد و به نحوی، تجربه‌ی آن ۵۰۰ نفر را کسب خواهیم کرد. به نظر من، کتاب و کلاس خیلی مفید نخواهند بود تا وقتی که خودمان به‌صورت عملی دست به کار نشویم. تا زمانی که به سراغ مسائل نرویم و شروع به کار نکنیم، از نظر من اتفاقی نمی‌افتد. خوب است که خودمان روی پروژه‌ی شخصی یا درسی کار کنیم. همین‌طور بسیار مهم است که زمان زیادی را در اینترنت و به جستجو کردن بگذرانیم. سایت‌هایی مثل stackoverflow بسیار مفید هستند، از این جهت که این حوزه سریع و دائماً در حال تغییر است درنتیجه جست‌وجوکردن و خواندن پرسش و پاسخ‌ها در این سایت‌ها، می‌توانند از کتاب خواندن مفیدتر باشد. خیلی از افراد باسواد لزوماً کتاب ننوشته‌اند اما ممکن است پاسخ سؤالی را در stackoverflow بدهند.

۲۳. حرف آخر؟

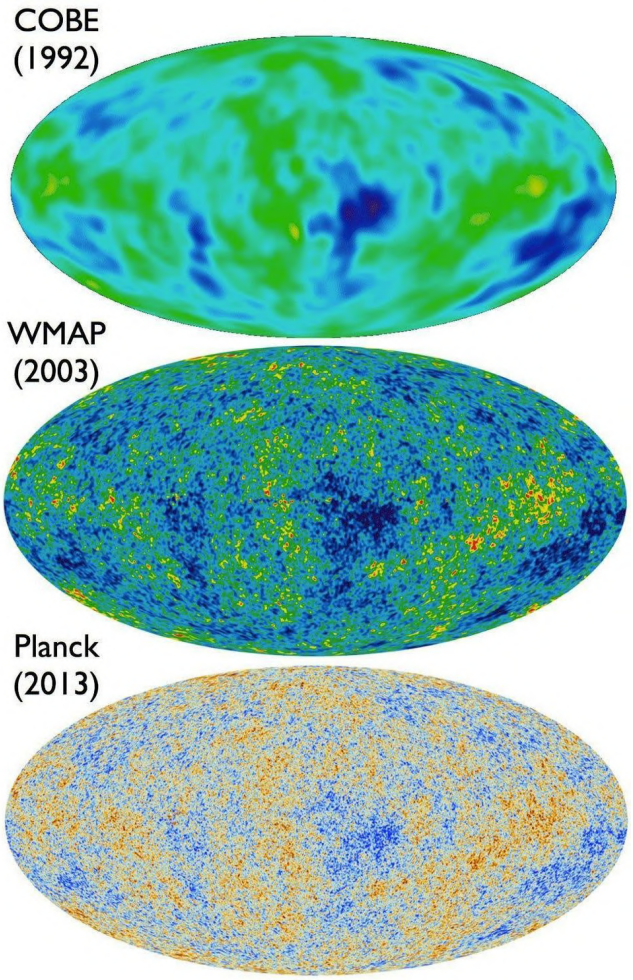
در ایران نسبت به کشورهای توسعه‌یافته در مواردی مثل ساخت CPU تفاوت فاحشی وجود دارد. اما در حوزه‌ی نرم‌افزار این‌گونه نیست؛ توسعه پیدا کرده‌است و افراد زیادی در آن فعالیت می‌کنند. حوزه‌ی کم‌هزینه‌ای است. کاری نیست که به پیش‌زمینه‌ی زیادی نیاز داشته‌باشد و افراد زیادی باید کار کرده‌باشند. برای مثال اگر کسی چندین پسادکترای هوافضا داشته باشد، باز هم نمی‌توانند همینطور وارد حوزه‌ی کار شود چون ممکن است تجهیزات نباشد. حوزه‌ی نرم‌افزار اما پیش‌نیازهای کمتری برای ورود به کار دارد از این نظر که خیلی لازم نیست به دانشگاه یا تجهیزات تکیه کنیم. می‌توانیم بخش زیادی را خودمان یاد بگیریم و کار کنیم و حتی کدمان را برای بقیه در جایی مثل github به نمایش بگذاریم.

برای کار کلاسیک برای مثال باید ۱۲ سال درس خواند تا دکترا گرفت. اما با حدود ۵ یا ۶ سال می‌توان senior data scientist شد و شروع به کار کرد. درنتیجه حوزه‌ای است که سرمایه‌گذاری برای آدم‌ها می‌طلبد. همین‌طور با توجه به حرفی که درمورد حرکت بشر از کار یدی و عملی به کار فکری و مدیریتی زدم، به‌نظرم نیاز است که هرکس وارد این حوزه شود و درمورد آن بیشتر بداند. متخصصان باید بتوانند ارتباط خوبی با ابزار محاسباتی داشته باشند، زیرا حضور این ابزارها در زندگی به مرور زمان بیشتر خواهد شد و کمتر نمی‌شود.

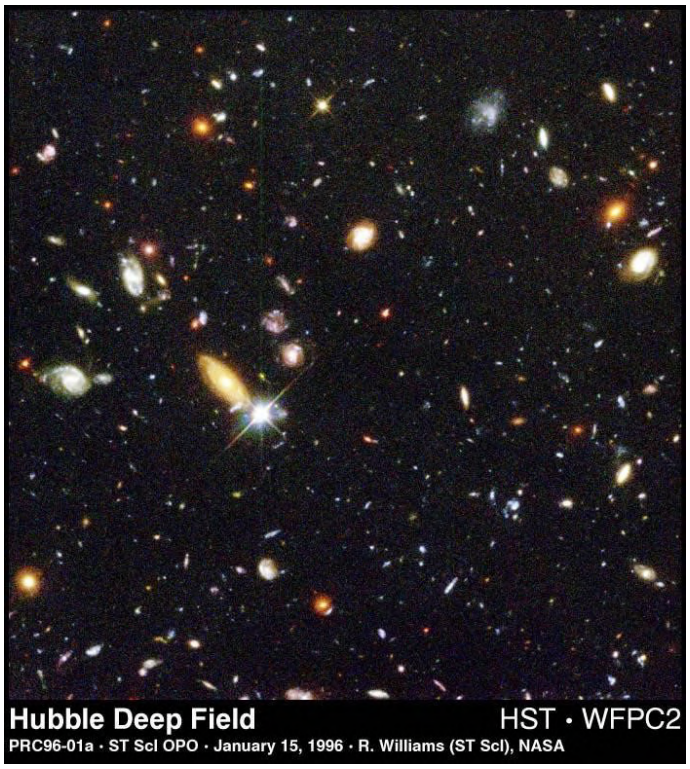
کیهان‌شناسی در سایه‌ی رصدها و داده‌های جدید

نویسنده: هاله مسگری

برای آغاز می‌توان گفت در فواصل دورتر از نقطه‌ی آبی رنگ‌پریده، ابعاد به صورتی تغییر خواهند کرد که تمام آن‌چه هستیم از یک نقطه، به یک اتم در درون اقیانوس بزرگی تبدیل خواهد شد. انسان مدرن هم مانند اجداد خود، سر را رو به آسمان بلند می‌کند و آن‌قدر رویا می‌بافد که هرچند وقت یک‌بار خبر فرستادن تلسکوپ جدید و جمع‌آوری داده‌های جدید را برای شناختن بهتر اقیانوسی که با آن مواجه هستیم، می‌شنویم. او در میانه ایستاده است تا خود را آماده‌ی شناختن هرچه بیشتر دنیای اطراف در ابعاد بسیار کوچک و بسیار بزرگ کند. کیهان‌شناسی، دانش آسمان در ابعاد بسیار بسیار بزرگ است. رویکردهای نظری و رصدی برای شناخت این دنیای ناشناخته در سال‌های اخیر آن‌قدر به هم نزدیک بوده‌اند که تصور آن شاید در ابتدا مقداری سخت باشد. اما برای درک بهتر آن می‌توان از یکی از مجموعه پروژه‌های جذاب این حوزه شروع کرد: تابش ریزموج پس زمینه‌ی کیهان. همان‌طور که انتظار می‌رود علم همیشه پر از تصادف‌های باورنکردنی‌ست؛ برای نمونه، کشفی که نشان داد بخشی از نوفه‌ی موجود در تلویزیون خانه، شاید مربوط به ۳۸۰/۰۰۰ سالگی کیهان باشد.



مقایسه داده‌های تابش ریزموج پس‌زمینه‌ی کیهان دریافت شده توسط سه ماهواره‌ی COBE،WMAP و Planck به ترتیب در سال‌های ۱۹۹۲، ۲۰۰۳ و ۲۰۱۳.[1]



تصویر منتشرشده توسط ناسا که تعداد ۱۰۰۰۰ کهکشان را با شکل‌ها، رنگ‌ها و سن‌های متفاوتی را نشان می‌دهد. این تصویر، قسمت کوچکی از فضا را در صورت فلکی کوره نشان می‌دهد که توسط تلسکوپ هابل در ۲۶ دسامبر سال۱۹۹۵گرفته شد.[2]

1-https://medium.com/starts-with-a-bang/how-the-planck-satellite-forever-changed-our-view-of-the-universe-3b94484f376d

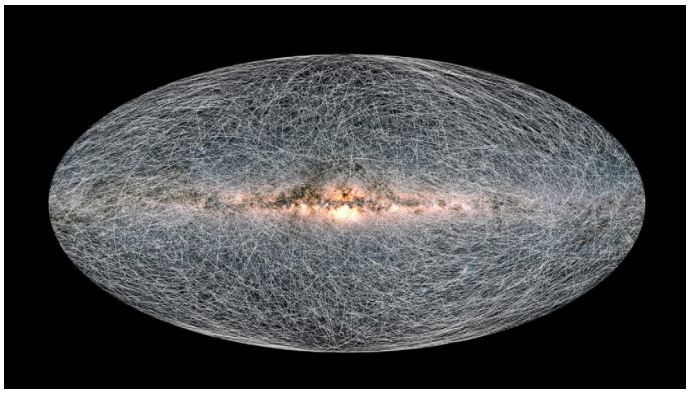
2-http://personal.psu.edu/wnb3/astro1/slideshows/class01/slides-01.html

در سال ۱۹۹۲ ماهواره‌ی COBE موفق به شناخت بیشتر این نوفه شد و تصویری محو از تابش ریزموج پس زمینه‌ی کیهان ارائه داد.

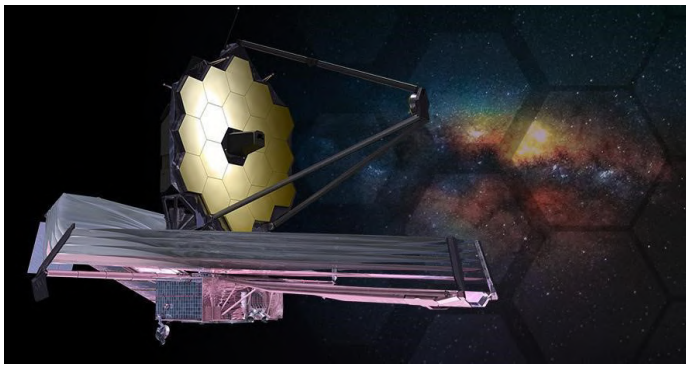
در سال ۲۰۰۳ داده‌های بیشتری از تابش ریزموج پس زمینه‌ی کیهان توسط ماهواره‌ی WMAP ارائه شد. همچنین پس از ۱۰ سال ماهواره‌ی پلانک با وضوح بالا و تعداد داده‌های بسیار بیشتر، دمای کیهان در زمان ۳۸۰/۰۰۰ سالگی را تا حدود ۳ کلوین تخمین زد. حال با استفاده از داده‌های ماهواره‌ی پلانک می‌دانیم، ناهمسانگردی‌های مشاهده شده از مرتبه‌ی میکرو-کلوین در داده‌های تابش پس زمینه‌ی کیهان، مانند بذرهایی در ساختار فضا-زمان رفتار می‌کنند. این بذرها در طی میلیاردها سال در فضا-زمان رشد کرده‌اند و کهکشان‌ها را تشکیل می‌دهند. با توجه به این‌که بخش بزرگی از دانش ما از کیهان توسط پیشرفت‌های رصدی و در سال‌های اخیر کسب شده است، عمر این دانسته‌ی ما به یک دهه هم نمی‌رسد. درست همان‌طور که اولین تصویر نشان دهنده‌ی کهکشان‌ها در سال ۱۹۹۶ توسط تلسکوپ فضایی هابل دانسته‌های ما را به طرز عجیبی متحول کرد. کیهان اطراف ما از ابعاد کهکشان راهِ شیری به سرعت به صدها هزار میلیارد کهکشان تغییر کرد.

همچنین در بین بسیاری از پروژه‌های دیگر شناخت کیهان، پروژه‌ی معروف رصدخانه‌ی LIGO نیز قابل توجه است. این رصدخانه از روی سطح زمین، اولین مشاهده‌ی انسان از امواج گرانشی را در سال ۲۰۱۶ به ثبت رساند. بعد از سال‌ها تلاش، داده‌های حاصل از امواج برخورد دو سیاهچاله در کیهان را دریافت و مشاهده کرده و پیش‌بینی نظریه‌ی نسبیت عام اینشتین را به اثبات رساند. تلسکوپ‌ها، ماهواره‌ها و پروژه‌های بسیاری وجود دارند که با دریافت مجموعا ۹۰ ترابایت داده در شبانه روز از آسمان، پایان ناپذیر بودن کنجکاوی انسان را در شناخت کیهان نشان می‌دهند. نمونه‌ی دیگر از این پروژه‌ها، تلسکوپ فضایی GAIA است که در سال ۲۰۱۳ شروع به جمع‌آوری داده کرده است. این تلسکوپ فضایی که انتظار می‌رود تا سال ۲۰۲۵ به جمع‌آوری داده ادامه دهد، وظیفه‌ی تهیه‌ی بزرگ‌ترین و دقیق‌ترین نقشه‌ی موجود از کهکشان راه شیری را بر عهده دارد. همچنین آشکار کردن ساختار و تحول کهکشان‌مان نیز از وظیفه‌های این تلسکوپ فضایی است.
در یک ماه گذشته شاید کمتر کسی باشد که خبر فرستاده شدن تلسکوپ فضایی جیمز وب را نشنیده باشد. این تلسکوپ پس از چند دهه تلاش با پیشرفت‌هایی باورنکردنی در تکنولوژی‌های به کار رفته در ساخت آماده‌ی آن است تا چشمان ما را به روی موضوعاتی باورنکردنی بگشاید!

پیوند دانش تئوری همراه با دانش رصدی در دهه‌های اخیر آن‌چنان ناگسستنی است که برای اثبات تمام آن‌چه کیهان‌شناسان می‌دانند، باید مشاهده‌ای صورت بگیرد. هر شب که سر به هوا می‌شویم و نور پیکسلی از آسمان را دریافت می‌کنیم، به ابعاد یک اتم در مقابل یک اقیانوس بیشتر می‌اندیشیم و نقطه‌ی آبی رنگ پریده از همیشه ناچیزتر است.



تصویر دقیق از کهکشان راه‌شیری انتشار یافته توسط تلسکوپ فضایی GAIA[3]



تصویری انتزاعی از تلسکوپ فضایی جیمزوب. در این تصویر ۱۸ آینه‌ی شش ضلعی از جنس بریلیوم، پوشیده شده از طلا و همچنین سپرهای خورشیدی این تلسکوپ نشان داده شده است.[4]

3-https://www.esa.int/ESA_Multimedia/Videos/2020/12/Gaia_s_stellar_motion_for_the_next_1.6_million_years

4-https://www.asc-csa.gc.ca/eng/satellites/jwst/Default.asp

یادگیری ماشینی به عنوان ابزاری برای شناخت و شهود پیدا کردن نسبت به مدل‌های نظری کیهان شناسی

نویسنده: فریدا فارسیان
محقق پسادکتری فیزیک دانشگاه بولونیا ایتالیا

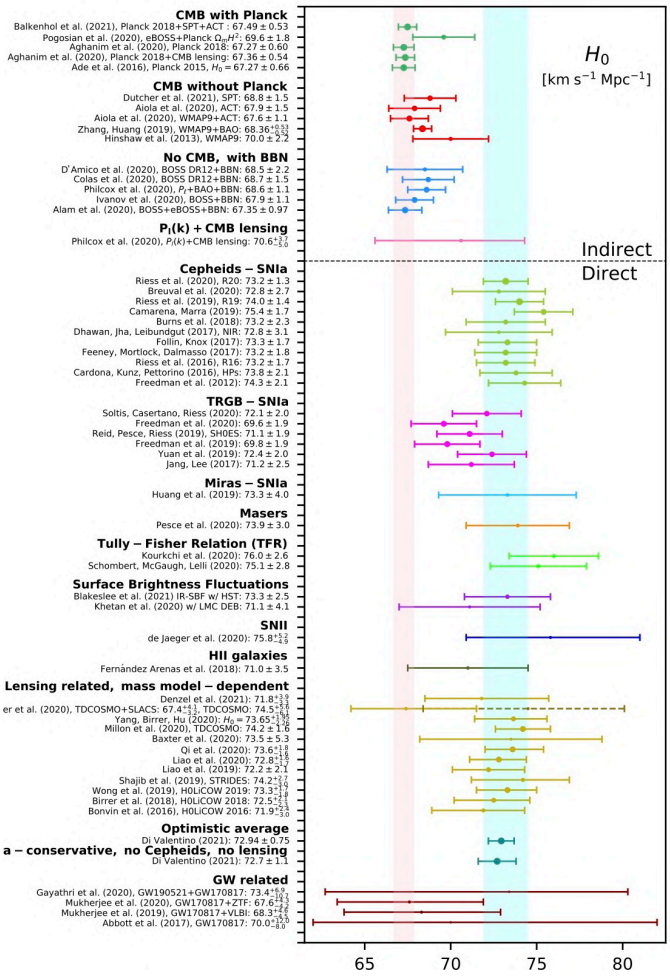
یادگیری ماشینی (Machine Learning) به‌عنوان زیرشاخه‌ای از هوش مصنوعی، به روشی اطلاق می‌شود که ماشین بدون نیاز به برنامه‌نویسی مستقیم، توانایی یادگیری اطلاعات مشخصی در یک مجموعه از داده را داشته‌باشد. در این روش، ماشین بر اساس الگوهای مشخص در داده و تجربیاتی که به‌دست می‌آورد، آموزش می‌بیند و پیش‌بینی‌هایی را به کاربر ارائه می‌کند. اگرچه در دهه‌ی اخیر استفاده از فناوری یادگیری ماشینی به‌صورت نمایی افزایش پیدا کرده‌است و آن را در جای‌جای زندگی روزمره‌ی خود مشاهده می‌کنیم، اما این فناوری برای اولین بار در سال ۱۹۵۹ توسط آرتور ساموئل معرفی شد و علم نوظهوری نیست. در دهه‌ی اخیر، افزایش سرسام‌آور حجم داده‌ها از یک‌سو و پیشرفت چشمگیر تکنولوژیِ واحدهای پردازشِ محاسباتی و گرافیکی از سوی دیگر، شرایط را برای فرمانروایی یادگیری ماشینی بر حوزه‌ی علم داده فراهم کرده‌اند. این فناوری به‌صورت گسترده در صنایع گوناگون، تجارت و امور مالی به‌کارگرفته می‌شود. همچنین کاربردهای فراوانی از این فناوری را در علوم پایه و انسانی می‌توان مشاهده کرد. در این مقاله قصد داریم به این پرسش پاسخ دهیم که آیا با به‌کارگیری یادگیری ماشینی در علم کیهان‌شناسی و اخترفیزیک، می‌توانیم به مدل‌های فیزیکی جدیدی برسیم که دریچه‌ی جدیدی را برای شناخت بهتر این علم به‌روی ما بگشاید؟

در حال حاضر مدل استاندارد کیهان‌شناسی (ΛCDM) بهترین نظریه‌ای است که می‌توانیم جهان پیرامون خود را با آن توصیف کنیم. این نظریه به‌صورت بسیار خلاصه، بر پایه‌ی متریک FRLW، معادلات فریدمان و نسبیت عام اینشتین بنا شده‌است و فرض می‌کند که ۶۸٪ کیهان از انرژی تاریک و ۲۸٪ از ماده‌ی تاریک تشکیل شده و ماده‌ی باریونی (ماده‌ی معمولی که ما به خوبی می‌شناسیم)، تنها سازنده‌ی ۴٪ از کیهان است. این مدل تا حد بسیار خوبی با رصدهای به‌عمل‌آمده در مقیاس‌های گوناگون، از تابش پس‌زمینه‌ی کیهانی تا ساختارهای بزرگ مقیاس، هم‌خوانی دارد.

با وجود اینکه مدل استاندارد کیهان‌شناسی تاکنون از آزمون‌های بسیاری سربلند بیرون آمده‌است، ولی همچنان پرسش‌های زیادی بی‌پاسخ مانده‌اند. برای نمونه، هنوز ماده‌ی تاریک در آشکارسازهای ذرات شناسایی نشده و مدل استاندارد ذرات هیچ نماینده‌ی معتبری برای این ماده معرفی نمی‌کند و همچنین برای انرژی تاریک سازوکار فیزیکی تثبیت شده‌ای در دست نداریم که رفتار و خصوصیات انرژی تاریک را آن‌گونه که ما می‌شناسیم توضیح دهد. برای هر دو جزء تاریک سازنده‌ی کیهان نظریات زیادی ارائه شده‌است که به تلاش برای توضیح سازوکار انرژی و ماده‌ی تاریک پرداخته‌اند. گروهی دیگر تلاش کردند با تغییر و تعمیم نظریه‌ی گرانش اینشتین مشاهدات را توضیح دهند. برای محدودکردن این نظریات، به مشاهدات دقیق از کهکشان‌ها و ساختارهای بزرگ‌مقیاس کیهانی نیاز داریم.

اما داستان مشکل‌های مدل استاندارد کیهان‌شناسی در اینجا تمام نمی‌شود. چند سالی است که سروکله‌ی تنشی در اندازه‌گیری ثابت هابل بین مساحی کیهان اولیه و کیهان متاخر پیدا شده‌است. این تنش که تا زمان نگارش این مقاله به ۵ سیگما رسیده‌است نشان می‌دهد آنچه ما از آهنگ انبساط کیهان در زمان تابش پس‌زمینه‌ی کیهان با آنچه در کیهان موضعی خود از ابرنواخترها اندازه می‌گیریم تفاوت دارد. با توجه به مقالات اخیر به نظر نمی‌رسد که دلیل این اختلاف در خطاهای سیستماتیک جا خوش کرده باشد! دانشمندان به‌دنبال تغییر در مدل‌های نظری کیهان‌شناسی، چه در کیهان اولیه چه در کیهان متاخر هستند.

برای حل این مشکلات و پرسش‌ها، داده‌های ماهواره‌ها و آرایه‌های تلسکوپی نقش مهمی ایفا می‌کنند. به‌طور مثال ماهواره‌ی اقلیدس (Euclid) با هدف مساحی مقیاس‌های بزرگ کیهان و حدگذاشتن بر روی مدل‌های انرژی تاریک سال آینده به فضا پرتاب خواهد شد و سیل عظیمی از داده‌ها را راهی مراکز تحقیقاتی خواهد کرد. بدین ترتیب فناوری‌ای باید وجود داشته‌باشد که بتواند این حجم وسیع از داده‌ها را با مدل‌های گوناگون مقایسه و بهترین جواب را در کمترین زمان ارائه کند.



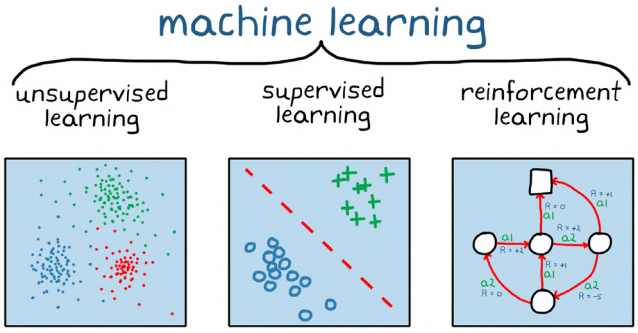
این نمودار مقدار ثابت هابل را که با روش‌های گوناگون اندازه‌گیری شده نشان می‌دهد و به وضوح می‌توان دید که باهم تفاوت غیرقابل اغماضی دارند. محدوده‌ی صورتی رنگ اندازه‌گیری‌ها را از کیهان اولیه، و محدوده‌ی آبی اندازه‌گیری‌ها از کیهان متاخر را به تصویر می‌کشد. این نمودار از مقاله‌ی
https://arxiv.org/abs/2103.01183v3
گرفته شده است.

با توجه به مشکلات مطرح‌شده و توان محاسباتی لازم برای غلبه‌کردن بر آن‌ها، به نظر می‌رسد که روش‌های یادگیری ماشینی نمایندگان مناسبی هستند. در سال‌های اخیر تعداد مقالاتی که با استفاده از روش‌های یادگیری ماشینی در کیهان‌شناسی و اخترفیزیک منتشر شده‌اند به‌صورت توانی افزایش داشته‌است. اگرچه همچنان اعتماد جامعه‌ی علمی به این روش‌ها کامل جذب نشده‌است، اما حضور آن‌ها با توجه به حجم داده‌های آینده و بن‌بست تکنولوژیک افزایش سرعت محاسباتی پردازشگرها ناگزیر به نظر می‌رسد. بدین ترتیب یادگیری ماشینی رفته‌رفته جای خود را در میان روش‌های استاندارد تحلیل و مدل‌سازی داده‌های علمی در مجامع دانشگران و دانشمندان پیدا می‌کند. اما پرسش اساسی اینجاست که این روش‌ها چقدر می‌توانند در نظریه‌پردازی و ارائه‌ی مدل‌های نظری جدید نقش ایفا کنند؟

برای پاسخ به این پرسش نیاز داریم به‌صورت خلاصه رهیافت‌های اصلی یادگیری ماشینی را معرفی کنیم. یادگیری ماشینی را می‌توان به سه شاخه‌ی اصلی یادگیری نظارتی، (Supervised Learning) یادگیری غیرنظارتی (Non-Supervised Learning) و یادگیری تقویتی (Reinforcement Learning) تقسیم کرد. در یادگیری نظارتی برچسب‌هایی برای ماشین فراهم می‌شود و نمونه‌هایی از جواب درست در اختیار ماشین قرار می‌گیرد تا براساس آن‌ها جواب را برای داده‌هایی که توسط ماشین مشاهده نشده‌اند، تعمیم دهد. دو کاربرد اصلی این روش دسته‌بندی (Classification) داده‌ها و رگرسیون (Regression) می‌باشد.

همان گونه که از نام یادگیری غیرنظارتی می‌توان حدس زد، برخلاف یادگیری نظارتی در این روش ماشین بدون هیچ داده‌ی برچسب‌گذاری‌شده، تلاش می‌کند تا الگوهای احتمالی موجود در داده را استخراج کند. از این روش برای خوشه‌بندی (Clustering) و انتساب (Association) داده‌ها استفاده می‌شود. این در حالی است که سازوکار یادگیری تقویتی کاملا متفاوت است و از روانشناسی رفتارگرایانه الهام گرفته شده‌است. در این روش پاداش یا تنبیه‌هایی برای ماشین تعیین می‌شود و الگوریتم مورد نظر با بیشینه‌کردن پاداش و کمینه‌کردن تنبیه آموزش می‌بیند. هم‌اکنون بیشترین کاربرد یادگیری تقویتی در بازی‌های کامپیوتری است، اما به تازگی در علوم پایه و کیهان‌شناسی نیز راه خود را پیدا کرده‌است.

همچنین یکی از روش‌های بسیار محبوب در یادگیری ماشینی در سال‌های اخیر یادگیری عمیق (Deep Learning) است. یادگیری عمیق بر روش‌های مبتنی بر شبکه‌های عصبی مصنوعی (Artificial Neural Networks) تمرکز دارد و شبکه‌های عصبی مصنوعی از پردازش اطلاعات و گره‌های ارتباطی توزیع‌شده در سیستم‌های بیولوژیکی الهام گرفته‌اند. کوچکترین واحد محاسباتی این شبکه‌ها نورون‌ها هستند و از اتصال این نورون‌ها، لایه‌های شبکه تشکیل می‌شوند. به شبکه‌ی عصبی‌ای که بیش از دو لایه‌ی درونی داشته باشد، شبکه‌ی عمیق گفته می‌شود.



در این تصویر، سه شاخه‌ی اصلی یادگیری ماشینی، از چپ به راست، یادگیری غیرنظارتی برای خوشه بندی، نظارتی برای دسته‌بندی و یادگیری تقویتی با استفاده از روش پاداش دهی نشان داده شده است.[1]

در حال حاضر رهیافت نظارتی و غیرنظارتی در زمینه‌های گوناگون کیهان‌شناسی به‌کارگرفته‌شده این کاربردها، به‌صورت وسیعی در استخراج و آنالیز داده، مدل‌سازی و شبیه‌سازی‌ها بوده‌است. با توجه به رویکرد یادگیری نظارتی، این روش بیشترین کاربرد را در ستاره‌شناسی و کیهان‌شناسی داشته‌است. در این روش نتیجه‌ی نهایی به برچسب‌های فراهم‌شده، به عبارتی به مدل اولیه و دانش کاربر از داده‌ها، بستگی مستقیم دارد. در نتیجه برای استخراج فیزیک جدید از داده‌های در دسترس نمی‌تواند مفید باشد. اما در درک بهتر مدل‌های نظری موجود می‌توانند به کمک ما بیاید.

رویکردهای غیرنظارتی برای پیدا کردن ساختارها و الگوهای جدید در داده‌ها مناسب‌تر هستند ولی مشکلی که اغلب در این دسته به آن برمی‌خوریم تفسیرپذیری (interpretability) نتایج به‌دست‌آمده است. گاهی این الگوریتم‌ها معیار (Cost function) خود را برای بهینه‌کردن سیستم به گونه‌ای تعریف می‌کنند که لزوماً با هدف علمی آن تحقیق هم‌خوانی ندارد؛ در نتیجه در بسیاری از پژوهش‌ها روش‌های تلفیقی یا نیمه‌نظارتی (Semi-supervised) استفاده می‌شود.

همان‌گونه که گفته شد، یادگیری ماشینی در عرصه‌ی ارائه‌ی مدل‌های نظریِ تازه بسیار نوپاست. اما در اینجا به دو نمونه‌ی اخیر در این باره اشاره می‌کنیم. به دلیل وجود ماده‌ی تاریک به‌صورتی که مستقیم نمی‌توان آن را مشاهده کرد، اهمیت ارتباط پارامترهای مشاهداتی اخترفیزیکی به هاله‌های ماده تاریک و کیهان‌شناسی دو چندان شده‌است.

به‌طور مثال، مقاله‌ای که شهریور امسال در arxiv:astro-ph منتشر شد، با استفاده از یادگیری عمیق رابطه‌ی جدیدی برای تخمین جرم کل هاله‌ها و زیرهاله‌های ماده‌ی تاریک ارائه کرده‌است[2]. در این پژوهش که توسط تیم تحقیقاتی دانشگاه پرینستون انجام شده، شبکه‌ی عصبی با استفاده از روش رگرسیون سمبولیک (Symbolic Regression) با در دست داشتن پارامترهایی مانند شعاع، پراکندگی سرعت، بیشینه‌ی سرعت، نرخ ستاره‌زایی و جرم ستاره‌ای زیرهاله، آموزش می‌بینند تا رابطه‌ای جهانی را از پارامترهای داده شده استخراج کنند. این شبکه از داده‌های شبیه‌سازی هیدرودینامیک کمل[3] (CAMELS) برای آموزش استفاده می‌کند. در این مقاله نشان داده شده‌است که رابطه‌ی جهانی یافت‌شده توسط ماشین، می‌تواند جرم کل زیرهاله را برای هر نوع زیرهاله‌ای، شامل هرگونه کهکشانی، در سرخ‌گرایی‌های گوناگون، با شبکه‌بندی و تفکیک‌پذیری متفاوت، با دقت بالایی پیش‌بینی کند. رابطه‌ی استخراج‌شده توسط شبکه در این تحقیق بر اساس سه پارامتر شعاع، پراکندگی سرعت و سرعت بیشینه‌ی هاله داده شده‌است در حالی که اگر از کیهان‌شناسان رصدی بپرسید به شما خواهند گفت که جرم ستاره‌ای و ستاره‌زایی از مهم‌ترین پارامترهای تعیین جرم کل زیرهاله هستند. این نشان می‌دهد که همواره نتیجه‌ای که از ماشین دریافت می‌کنیم مطابق انتظار ما نخواهد بود و در این حالت تفسیرپذیری نتایج و آگاه بودن به تمام ظرایف روش یادگیری ماشینی اهمیت اساسی پیدا می‌کند.

از سویی دیگر، در شبیه‌سازی‌های مقیاس‌های بزرگ کیهانی به‌صورت متداول و با توان محاسباتی به نسبت پایین‌تر، می‌توان هاله‌های ماده‌ی تاریک را در سرخ‌گرایی‌های گوناگون، از ابتدای کیهان تا به امروز، محاسبه و اجرا کرد. در مرحله‌ی بعد آنچه اهمیت دارد، نسبت‌دادن کهکشان‌ها به هاله‌های ماده تاریک است، بدین صورت می‌توانیم آنچه که در رصدهای خود می‌بینیم را با شبیه‌سازی‌ها مطابقت دهیم. برای این کار مدل‌های تحلیلی گوناگونی مانند توزیع اشتغال هاله‌ها (Halo Occupation Distribution) وجود دارد و یا می‌توان از شبیه‌سازی‌های هیدرودینامیکی استفاده کرد که ماده‌ی باریونی را در شبیه‌سازی لحاظ می‌کنند. چالش انجام این‌گونه شبیه‌سازی‌ها این است که از نظر محاسباتی بسیار زمان‌بر و پرهزینه هستند، در نتیجه معمولاً در مقیاس‌های کوچک‌تر نسبت به شبیه‌سازی‌های

1-https://www.mathworks.com/discovery/reinforcement-learning.html

2-https://arxiv.org/abs/2109.04484

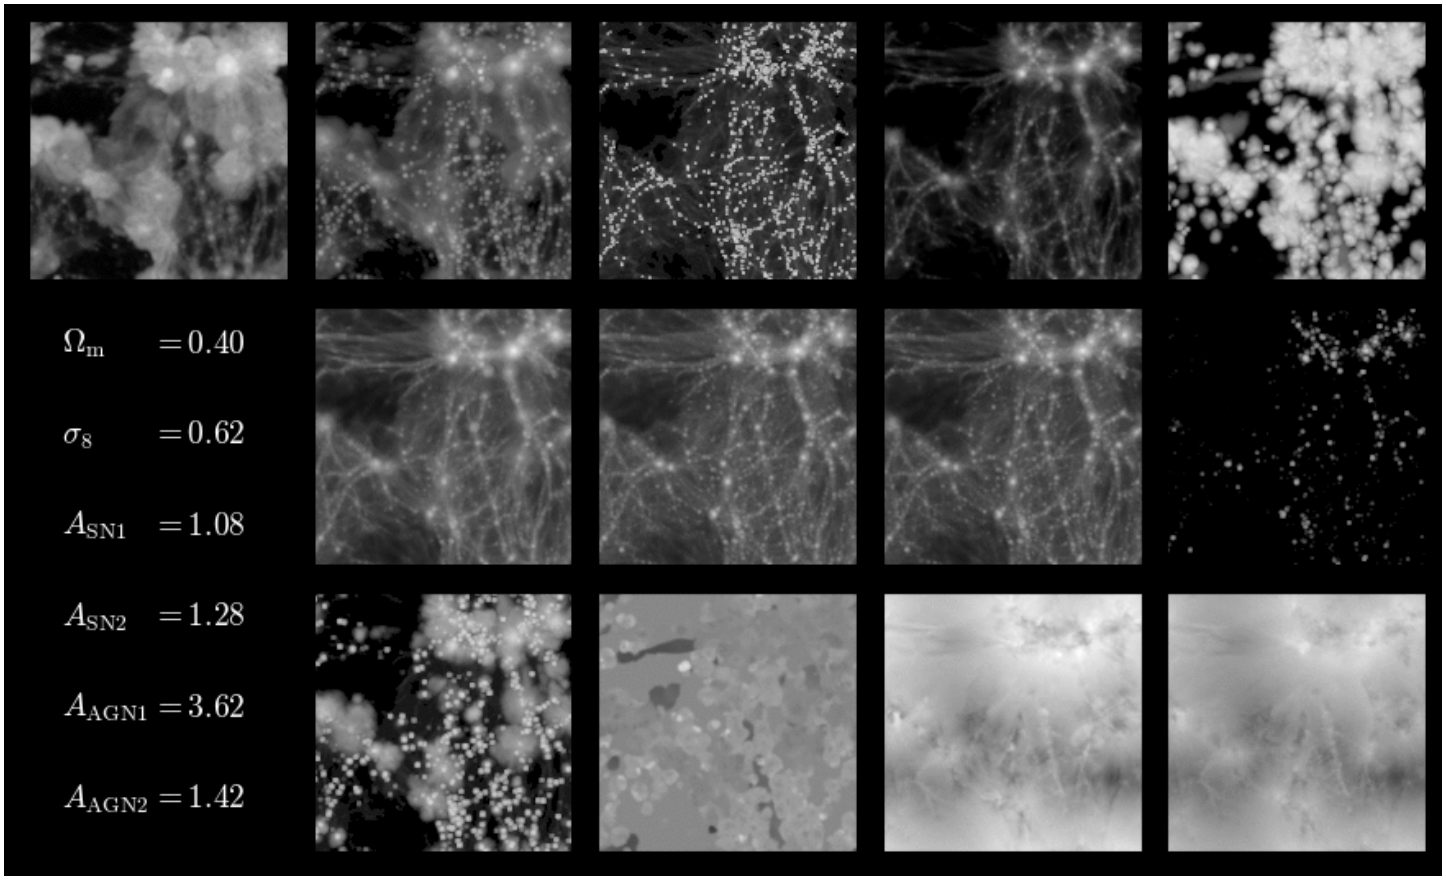
3-https://camels-multifield-dataset.readthedocs.io/en/latest/

مـاده‌ی تاریـک انجـام می‌شـوند. در ایـن زمینـه بـه تازگـی مقالـه‌ای منتشـر شده‌اسـت کـه بـا ترکیـب یادگیـری عمیـق و یادگیـری تقویتـی بـه هاله‌هـای مـاده‌ی تاریـک کهکشـان نسـبت می‌دهنـد[۴] (Galaxy net). در ایـن پژوهـش بـا در نظـر گرفتـن کاتالـوگ هاله‌هـای مـاده‌ی تاریـک از ماشـین خواسـته شده‌اسـت کـه بـه هـر زیرهالـه به‌صـورت تصادفـی کهکشـانی نسـبت دهـد و کاتالوگـی از کهکشـان‌ها بسـازد، در مرحلـه‌ی بعـد کاتالـوگ ساخته‌شـده بـا کاتالـوگ کهکشـان‌های رصدشـده مقایسـه می‌شـود، در اینجـا الگوریتـم یادگیـری تقویتـی تعییـن می‌کنـد کـه اگـر کهکشـان نسبت‌داده‌شـده بـا آنچـه کـه مـورد انتظـار اسـت مطابقـت دارد، بـه ماشـین پـاداش دهـد. بدیـن صـورت ماشـین تـلاش می‌کنـد تـا پـاداش خـود را بیشـینه کنـد. مزیـت ایـن روش ایـن اسـت کـه شـبکه‌ی عصبـی مذکـور به‌صـورت مسـتقیم بـا اسـتفاده از داده‌هـای رصـدی آمـوزش دیده‌اسـت و در نتیجـه اعتمـاد بـه کاتالـوگ کهکشـان ساخته‌شـده می‌توانـد بسـیار بـالا باشـد.

بـر اسـاس چالش‌هـای بیان‌شـده و نمونه‌هـای موجـود در ایـن زمینـه، بـه نظـر می‌رسـد یادگیـری ماشـینی راه درازی را در پیـش رو دارد تـا بتوانـد در حـوزه‌ی مدل‌سـازی تئـوری نقـش مهمـی ایفـا کنـد. در وهلـه‌ی اول نیـاز داریـم تـا سـازوکار یادگیـری ماشـینی را بـه خوبـی بشناسـیم و آن را بـه چشـم جعبـه‌ای جادویـی نبینیـم. بـرای علـم مـدرن، آزمایش‌کـردن نظریـات تئـوری ارزش بی‌همتایـی دارد و بـرای هـر آزمایشـی خطـای آن مهم‌تریـن عامـل اسـت. در نتیجـه ضـروری اسـت تـا خطـای روش‌هـای یادگیـری ماشـینی را بـه خوبـی تعییـن کنیـم. در ایـن زمینـه شـبکه‌های عصبـی بیـزی (Bayesian Neural Networks) کمـک شـایانی کرده‌انـد.

بـه نظـر نویسـنده، اگـر بخواهیـم از بیـن روش‌هـای یادگیـری ماشـینی یکـی را برگزینیـم کـه مـدل نظـری جدیـدی ارائـه دهـد و تحولـی در شـناخت مـا از کیهـان ایجـاد کنـد، یادگیـری تقویتـی از بهتریـن انتخاب‌هـا خواهـد بـود.

در نهایـت در پاسـخ بـه پرسـش اولیـه کـه در ایـن متـن مطـرح کردیـم، می‌تـوان گفـت در حـال حاضـر یادگیری ماشـینی کمک می‌کنـد تـا روابـط و معـادلات جدیـدی از دل شبیه‌سـازی‌ها و رصدهـای کیهان‌شناسـی بیـرون کشیده‌شـود ولـی در نهایـت ایـن فیزیک‌دان‌هـا هسـتند کـه بایـد ایـن روابـط را تفسـیر فیزیکـی کننـد و معنـای آن‌هـا را بـا توجـه بـه قوانیـن فیزیـک بیـرون بکشـند.



این تصویر یکی از حالت‌های شبیه‌سازی کمل را برای ماده‌ی تاریک و باریونی، با درنظر گرفتن مدل‌های مختلف بازخورد ماده‌ی باریونی، نشان می‌دهد.[۵]

4-https://doi.org/10.1093/mnras/stab1449

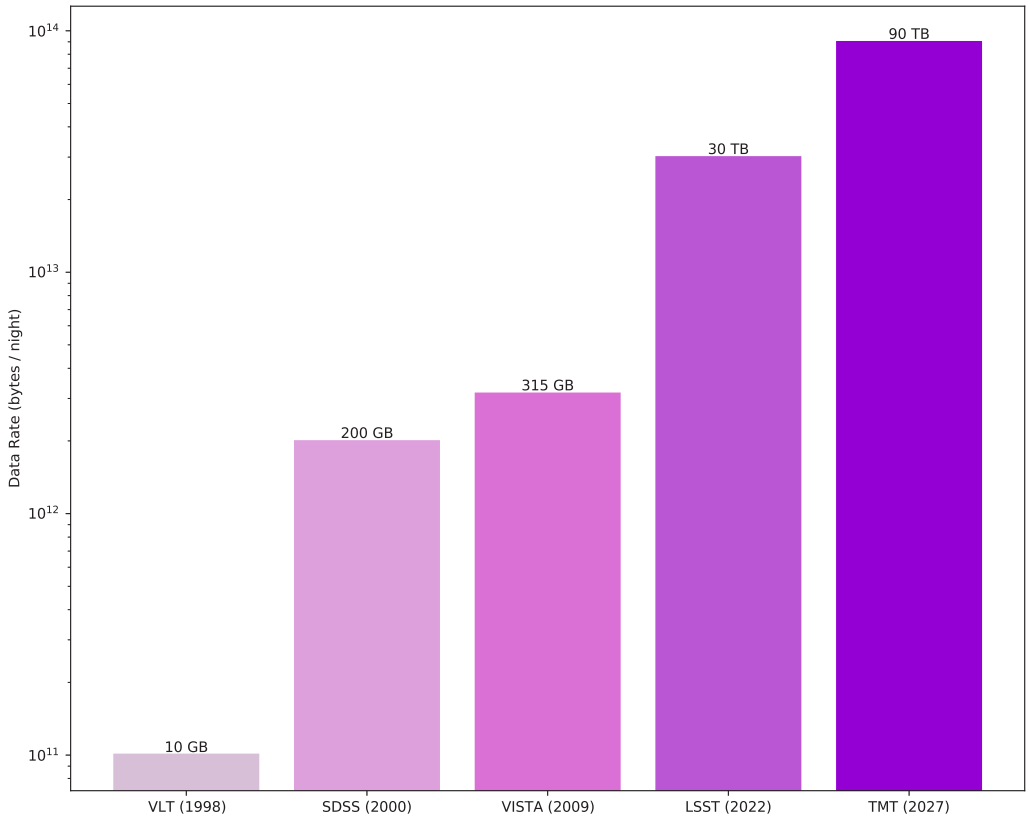
5-https://camels-multifield-dataset.readthedocs.io/en/latest/

یادگیری ماشینی به عنوان ابزاری برای کار با داده‌های بزرگ

نویسنده: نگین خسروانی‌نژاد

مشاهده در نجوم را می‌توان به «اندازه‌گیری نوری که از شیء‌های فضایی[1] می‌رسد» تقلیل داد. دو راه برای این کار وجود دارد که یکی از آن‌ها طیف‌سنجی[2] است. در طیف‌سنجی، تعداد دقیق فوتون‌ها در طول موج‌های مختلف، یا همان طیف[3]، اندازه‌گیری می‌شود. طیف اطلاعات زیادی درباره‌ی ترکیبات شیمیایی، ویژگی‌های کلی، سرعت حرکت و غیره به ما می‌گوید. رصدهای طیف‌سنجی در یک زمان تنها به اندازه‌گیری تعداد کمی شیء محدود می‌شوند و اغلب پرهزینه هستند، بنابراین راه دومی هم وجود دارد: نورسنجی[4]. در نورسنجی، نور را از طریق فیلترهای رنگی مختلف اندازه گیری می‌کنند. اگرچه این روش دقت کمتری دارد، اما به ما این امکان را می‌دهد که در یک تصویر، هزاران شیء را رصد کنیم و هم‌چنین اجسام کم‌نورتر یا دورتر را ببینیم.

نجوم و به‌خصوص کیهان‌شناسی سرشار از داده هستند. با ظهور تلسکوپ‌هایی با دهانه‌های بزرگ می‌توان



افزایش حجم داده‌های تلسکوپ‌ها در طول زمان: تلسکوپ بسیار بزرگ (VLT)، نقشه‌برداری آسمان دیجیتال اسلون (SDSS)، تلسکوپ مرئی و فروسرخ برای نجوم (VISTA)، تلسکوپ سینوپتیک بزرگ (LSST) و تلسکوپ سی متری (TMT)[5]

1-celestial objects

2-spectroscopy

3-spectrum

4-photometry

5-https://www.sciencedirect.com/topics/earth-and-planetary-sciences/dark-energy

نقشه‌برداری[۶]های عظیم‌تری از آسمان تولید کرد. مجموعه داده‌های کیهان‌شناسی با سرعتی نمایی در حال رشد هستند. این حجم عظیم از داده‌ها نیاز به تجزیه و تحلیل دارند: پردازش تصویر، تشخیص شیءها، طبقه‌بندی‌ها، پیش‌بینی‌ها و بسیاری موارد دیگر. این تجزیه و تحلیل‌ها را می‌توان با مدل‌های یادگیری ماشینی انجام داد. یادگیری ماشینی توانایی افزایش قدرت توضیحی رصدهای نورسنجی را دارد که ممکن است اطلاعات کمتری در مورد هر شیء جداگانه داشته باشند، اما به طور کلی داده‌های بیشتری را در مورد شیءهای بیشتری ارائه می‌دهند.

یکی از بزرگترین نقشه‌برداری‌های نجومی تا به امروز، نقشه‌برداری آسمانی دیجیتال اسلون[۷] یا به اختصار SDSS است. این تلسکوپ هر شب دویست گیگابایت داده تولید می‌کند و تا به امروز نزدیک به یک میلیون تصویر میدانی به دست آمده‌است که در آن بیش از دویست میلیون کهکشان و تعداد بسیار بیشتری ستاره شناسایی شده‌اند. [۱] نقشه‌برداری‌های آینده حتی داده‌های بسیار بیشتری را هم ارائه خواهند کرد. یکی از آن‌ها تلسکوپ بزرگ سینوپتیک (LSST) است که تصاویر وسیعی از آسمان را ارائه می‌کند و کهکشان‌هایی را نشان می‌دهد که با استانداردهای امروز، بسیار کم‌نور محسوب می‌شوند. هدف اصلی LSST کشف شیءهای گذرا[۸] است — شیءهایی که روشنایی آن‌ها در مقیاس‌های زمانی چند ثانیه تا چند ماه تغییر می‌کند. این تغییرات روشنایی می‌تواند ناشی از دلایل مختلفی باشد؛ بعضی از آن‌ها جالب نیستند ولی برخی دیگر رویدادهای بسیار نادری هستند که نباید آن‌ها را از دست داد. انتظار می‌رود LSST میلیون‌ها شیء گذرا را با حجم داده‌ی سی ترابایت در هر شب ثبت کند. [۲] این شیءها باید در لحظه شناسایی شوند تا امکان رصدهای بعدی فراهم شود. شکل یک نشان می‌دهد که چگونه آهنگ تولید داده افزایش یافته و با شروع نقشه‌برداری‌های جدید هم‌چنان افزایش خواهد یافت. با وجود این حجم بسیار زیاد داده، شناسایی درست و دقیق شیءها یک چالش بزرگ خواهد بود.

پس از این که داده‌های خام جمع‌آوری می‌شوند، به الگوریتم‌هایی نیاز داریم که اطلاعات را از آن‌ها استخراج کند. بسیاری از الگوریتم‌ها هنوز توسط انسان انجام می‌شوند و چالش‌ها و مشکلات زیادی دارند که هنگام انجام اتوماتیک الگوریتم‌ها هم ادامه پیدا می‌کنند. یکی از چالش‌ها این است که کیهان‌شناسی بر داده‌هایی با نوردهی طولانی متکی است. بنابراین اساساً در کیهان‌شناسی به الگوریتم‌های پردازش تصویر برای حذف نوفه علاقه‌مندیم. این مسئله به خصوص برای تشخیص اجسام کم‌نور با نسبت سیگنال به نوفه پایین مهم می‌شود. یکی دیگر از الگوریتم‌های حیاتی در نقشه‌برداری‌ها، الگوریتم تشخیص شیء است. معیارهای اساسی چنین الگوریتمی، اول کامل بودن و دوم قابل اطمینان بودن است. کامل بودن به تعداد شیءهای شناسایی شده اشاره دارد، در حالی که قابلیت اطمینان بودن به این ربط دارد که چه تعداد از شیءهای شناسایی شده درست هستند. به حداکثر رساندن این معیارها نیازمند تکنیک‌های یادگیری ماشینی است. به این ترتیب، یادگیری ماشینی در کیهان‌شناسی برای تجزیه و تحلیل داده‌های بزرگ، مبحثی است که به سرعت در حال تکامل است و با گذر زمان و تولید داده‌های عظیم‌تر، توجه‌های بیشتری را به خود جلب می‌کند.

یکی از مهم‌ترین مشکلات کیهان‌شناسی امروز، مسئله‌ی تنش هابل[۹] است. ثابت هابل[۱۰] اندازه‌گیری شده محلی با استفاده از ابرنواخترهای نوع یک که با ستاره‌های قیفاووسی کالیبره هستند، با آن چیزی که از اندازه‌گیری‌های تابش زمینه کیهان[۱۱] توسط ماهواره‌ی پلانک[۱۲] اندازه‌گیری می‌شود، با هم تطابق ندارند. ممکن است الگوریتم‌های یادگیری ماشینی تجزیه و تحلیل داده‌ها بتوانند این مسئله را متحول کند، زیرا در این الگوریتم‌ها سویدگی (بایاس) های ناشی از انتخاب مدل وجود ندارد. اگر الگوریتم‌های یادگیری ماشینی را به روی داده‌های ابرنواخترهای نوع یک-ای[۱۳] و مجموعه داده‌های تاریخچه انبساط کیهان اعمال کنیم، می‌توانیم و پارامتر $d_L(z)$ رابطه‌ی بین فاصله‌ی درخشندگی یعنی را به صورت مستقل از مدل بازسازی $H(z)$ هابل یعنی کنیم. برای این کار نیاز به هیچ پارامتر یا فرض هیچ مدل کیهان‌شناسی یا انرژی تاریک نداریم. سپس می‌توانیم با نتایجی که به دست می آوریم، پارامتر را تخمین بزنیم و ببینیم مدلی $q(z)$ کاهش شتاب یعنی که در انتقال به‌سرخ‌های متفاوت به این نتایج برازش می‌شود طبق مدل استاندارد کیهان‌شناسی است و یا از آن انحراف دارد. [۳] به این ترتیب، یادگیری ماشینی می‌تواند روش مناسبی برای کار با داده‌های بزرگ و برازش کردن در کیهان‌شناسی باشد.

منابع:

[۱] http://www.sdss.org
[۲] https://www.lsst.org
[۳] arXiv:1910.01529

6-survey
7-Sloan Digital Sky Survey (SDSS)
8-transients astronomical phenomena
9-Hubble tension
10-Hubble constant
11-cosmic microwave background (CMB)
12-Planck
13-Type Ia supernova

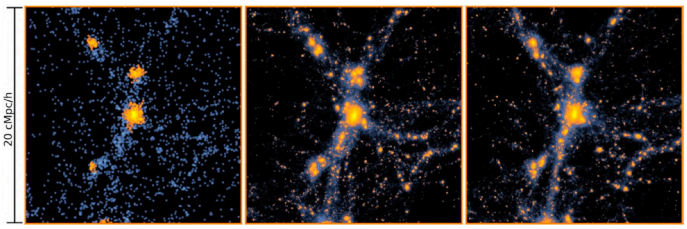
یادگیری ماشینی به عنوان جایگزینی سریع‌تر و بهینه‌تر در شبیه‌سازی‌ها

نویسنده: نگین خسروانی‌نژاد

شبیه‌سازی‌ها نقش مهمی در کشف اسرار کیهان‌شناسی از جمله اسرار ماده‌ی تاریک و انرژی تاریک بازی می‌کنند. کیهان‌شناسان از شبیه‌سازی برای پیش‌بینی اینکه جهان با مدل‌ها و سناریوهای مختلف چگونه رفتار می‌کند، استفاده می‌کنند. سپس داده‌های رصدی تأیید می‌کنند که آیا پیش‌بینی‌های شبیه‌سازی‌ها با واقعیت مطابقت دارند یا خیر. یکی از چالش‌های شبیه‌سازی‌های کیهانی این است که همه‌چیز را هم‌زمان ندارند. آن‌ها یا می‌توانند بر روی یک منطقه‌ی کوچک با قدرت تفکیک (رزولشن) بالا تمرکز کنند، و یا حجم زیادی از کیهان را با قدرت تفکیک پایین در برمی‌گیرند. با این حال، در اردیبهشت امسال (می ۲۰۲۱) گروهی از پژوهشگران ناسا با آموزش یک الگوریتم یادگیری ماشینی مبتنی بر شبکه‌های عصبی برای ارتقاء یک شبیه‌سازی از قدرت تفکیک پایین به قدرت تفکیک فوق‌العاده، توانستند بر این مشکل غلبه کنند. [۴]

برای ناحیه‌ای با وسعت تقریباً پانصد میلیون سال نوری در کیهان که حاوی ۱۳۴ میلیون ذره است، روش‌های موجود به ۵۶۰ ساعت زمان نیاز دارند تا با استفاده از یک هسته‌ی پردازشی شبیه‌سازی را با قدرت تفکیک بالا انجام دهند. با این حال، روشی مثل این که مبتنی بر یادگیری ماشین است، می‌تواند نتایج آن شبیه‌سازی‌ها را در مقیاس بزرگ و قدرت تفکیک پایین بگیرد و شبیه‌سازی‌هایی با قدرت تفکیک زیاد ایجاد کند که حاوی ۵۱۲ برابر ذرات بیشتر است. شبیه‌سازی جدید، تنها به ۳۶ دقیقه زمان برای اجرا شدن نیاز دارد. هنگامی که ذرات بیشتری به شبیه‌سازی اضافه شود، نتایج بهتر هم می‌شوند. برای جهانی هزار برابر بزرگتر با ۱۳۴ میلیارد ذره، اجرا شدن کد جدید در یک واحد پردازش گرافیکی ۱۶ ساعت طول می‌کشد. این در حالی است که با استفاده از روش‌های سنتی، شبیه‌سازی با این ابعاد و قدرت تفکیک با یک ابررایانه ماه‌ها طول می‌کشد. کاهش زمان لازم برای اجرای شبیه‌سازی‌های کیهان‌شناسی، باعث ایجاد پیشرفت‌های عمده در کیهان‌شناسی عددی[۱۴] خواهد شد.

این شبیه‌سازی با استفاده از از شبکه‌های عصبی پیش‌بینی می‌کند گرانش چگونه در طول زمان باعث حرکت ماده‌ی تاریک می‌شود. دو شبکه‌ی عصبی در مقابل یکدیگر قرار می‌گیرند. یک شبکه شبیه‌سازی‌های کیهان با قدرت تفکیک پایین را می‌گیرد و از آن‌ها برای تولید مدل‌های با قدرت تفکیک بالا استفاده می‌کند، شبکه‌ی دیگر سعی می‌کند این شبیه‌سازی‌ها را از شبیه‌سازی‌هایی که با روش‌های مرسوم ساخته شده‌اند تشخیص دهد. با گذشت زمان و آموزش داده‌های بیشتر، هر دو شبکه سازگارتر و دقیق‌تر می‌شوند تا اینکه در نهایت، مولد شبیه‌سازی برنده می‌شود و شبیه‌سازی‌های سریعی ایجاد



شبیه‌سازی منطقه‌ای از فضا به ابعاد صد میلیون سال نوری مربع با قدرت تفکیک پایین اجرا شد که بخشی از آن در سمت چپ دیده می‌شود. با استفاده از یادگیری ماشینی، پژوهشگران این مدل را برای ایجاد یک شبیه‌سازی با قدرت تفکیک فوق‌العاده در سمت راست ارتقا دادند. این شبیه‌سازی جزئیات مشابه یک مدل معمولی با قدرت تفکیک بالا در وسط را به تصویر می‌کشد در حالی که به منابع محاسباتی بسیار کمتری نیاز دارد.[۱۵]

می‌کند که دقیقاً مثل شبیه‌سازی‌های معمولی کند به نظر می‌رسند. مزیت شبکه‌های عصبی این است که علی‌رغم اینکه تنها با استفاده از داده‌های مناطق کوچکی از کیهان آموزش می‌بینند، می‌توانند ساختارهای بزرگ-مقیاس را که فقط در شبیه‌سازی‌های عظیم ظاهر می‌شوند، به دقت تکرار کنند. البته نمی‌توان گفت که چنین شبیه‌سازی‌ای همه‌چیز را دربرمی‌گیرد زیرا فقط بر ماده‌ی تاریک و گرانش تمرکز می‌کند و پدیده‌های کوچک-مقیاس مانند اثرات سیاهچاله‌ها و شکل‌گیری ستاره‌ها و ابرنواخترها کنار گذاشته شدند. اما الگوریتم‌های یادگیری ماشینی این قابلیت را دارند که با شبیه‌سازی‌های سنتی ترکیب شوند طوری گسترش پیدا کنند که نیروهای باعث پدیده‌های کوچک-مقیاس را هم شامل شوند. یادگیری ماشینی در بسیاری از علوم تاثیر زیادی داشته‌است و این نتیجه جدید نمونه‌ای است که چطور می‌تواند کیهان‌شناسی را متحول کند. شبیه‌سازی‌های کیهان‌شناسی سرنوشت کیهان را از ابتدا تا شکل‌گیری همه کهکشان‌ها و سیاه‌چاله‌ها دنبال می‌کنند. شبیه‌سازی‌های سنتی نشان می‌دادند که برای کشف فیزیک جدید می‌توانیم جهان را شبیه‌سازی کنیم، اما فقط در مقیاس‌های کوچک یا با قدرت تفکیک پایین. اما الگوریتم‌های یادگیری ماشینی، قادر خواهند بود بخش زیادی از جهانی که می‌شناسیم را به دقت شبیه‌سازی کنند.

منبع:

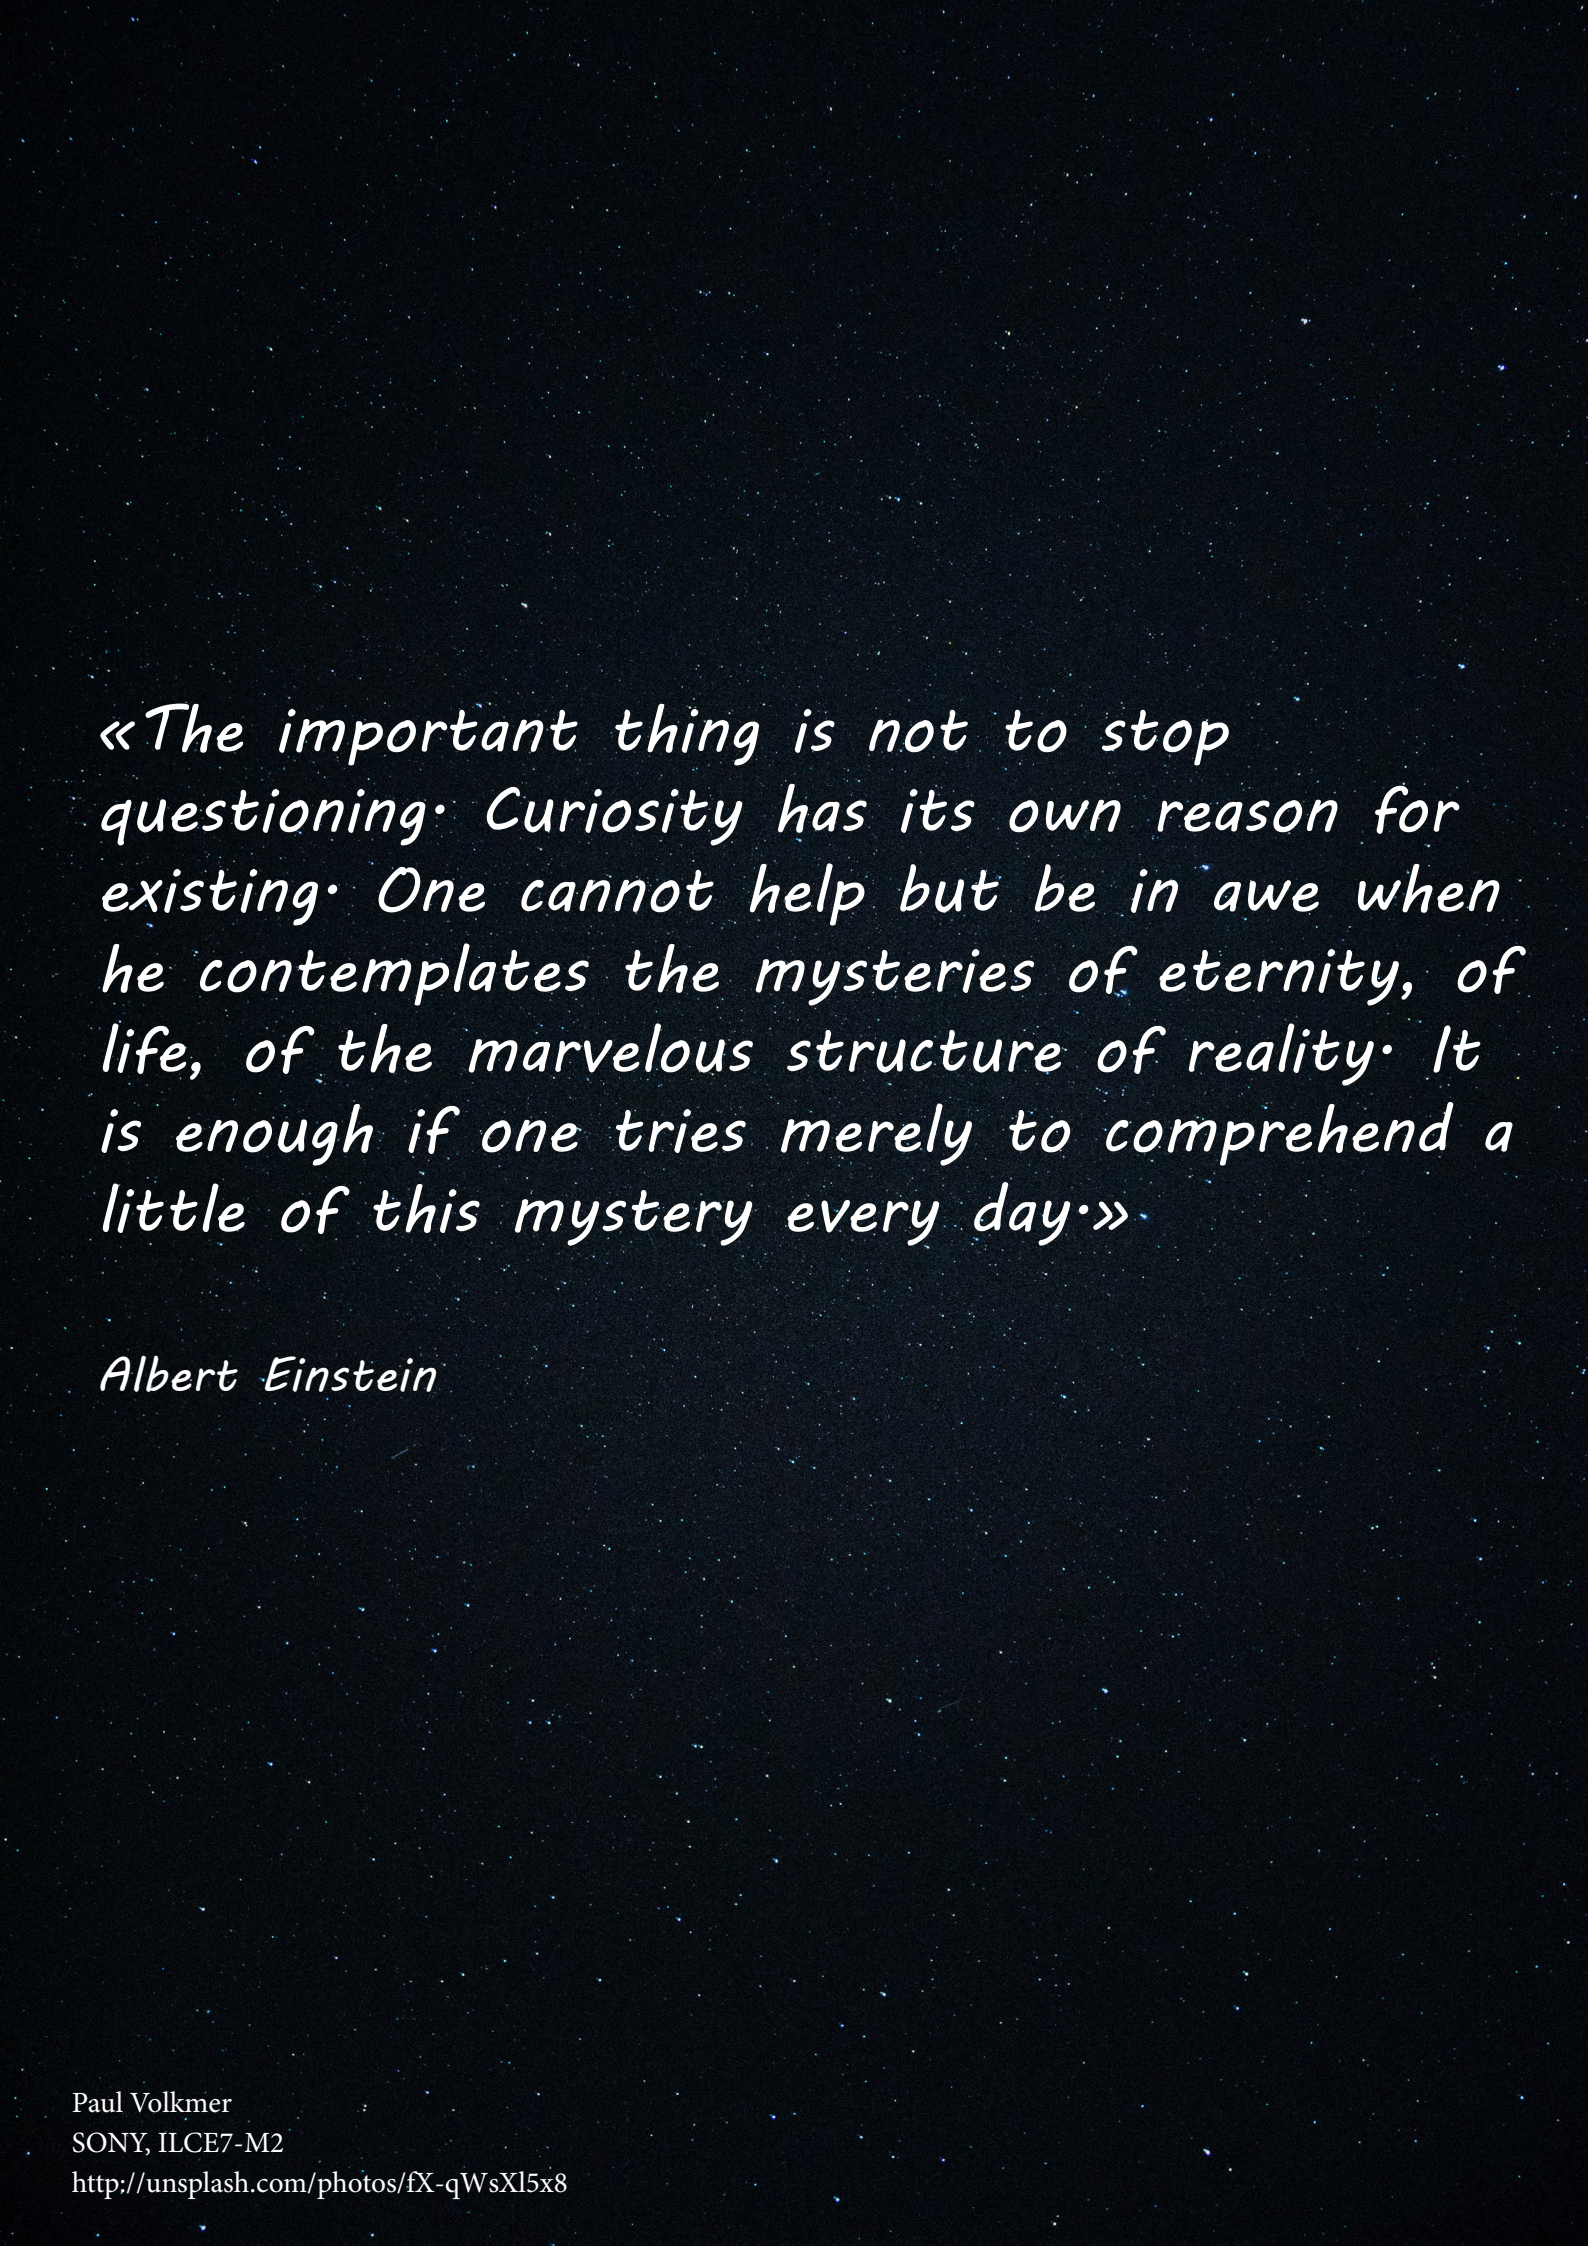
[۴] DOI: 10.1073/pnas.2022038118

14-numerical cosmology

15-https://www.cmu.edu/news/stories/archives/2021/may/machine-learning-cosmology.html



Raphael Nogueira
NIKON CORPORATION, NIKON D5200
http://unsplash.com/photos/svbDI1Pq30s



Paul Volkmer
SONY, ILCE7-M2
http://unsplash.com/photos/fX-qWsXl5x8